大模型与智能体技术-2026 秋

高水平学术论文

阅读报告

论文标题：V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning（V-JEPA 2:自监督视频模型实现理解、预测与规划）

作者：Mahmoud Assran,Adrien Bardes,David Fan,Quentin Garrido,Russell Howes,Mojtaba Komeili,Matthew Muckley,Ammar Rizvi,Claire Roberts,Koustuv Sinha,Artem Zholus, Sergio Arnaud1,Abha Gejji,Ada Martin,Francois Robert Hogan1,Daniel Dugas1,Piotr Bojanowski,Vasil Khalidov,Patrick Labatut,Francisco Massa,Marc Szafraniec,Kapil Krishnakumar,Yong Li, Xiaodong Ma,Sarath Chandar,Franziska Meier,Yann LeCun1,Michael Rabbat1,Nicolas Ballas1

发表期刊或会议：arXiv 预印本

发表时间：2025 年 6 月 13 日

论文网址：https://arxiv.org/abs/2506.09985

姓名：郑茂繁

学号：26053040

专业：电子信息

注意事项

1， 请选择 2025-2026 年度发表的与大模型或大模型智能体相关的高水平学术论文，优先选用在顶级期刊或会议发表的论文。

2， 只做 1 篇论文的精读阅读报告，不需要做多篇论文和论文研究综述。

3， 禁止使用任何大模型生成阅读报告内容，如疑似含有大模型生成内容，直接记 0 分。

4， 报告内容 2000 字以上。

5， 请将 docx 转换成 pdf 文件提交。

6， 文件命名：“学号-姓名-专业-阅读报告.pdf”如“26060101-张三-管理科学与工程-阅读报告.pdf”，并在头歌平台提交。

一、研究背景

智能体在开放环境中自主行动的前提，是对物理世界形成可用的内部表征。认知科学将这一表征称为世界模型：大脑整合低层次感觉输入，表征并预测未来状态，该内部模型反过来约束当下的知觉与判断。个体对自身行为后果的预测能力，构成目标导向规划的基础。从感官数据中学习世界模型，因而成为人工智能的基础性课题。

强化学习把世界模型置于决策回路内部，以状态—动作序列与奖励信号学习潜在动力学，并在想象空间中优化策略。此类方法的有效性建立在任务内交互数据之上。真实世界交互数据获取成本高、覆盖分布窄，模型难以扩展到开放环境；奖励设计的任务依赖性进一步限制了跨任务迁移。数据规模由此成为该范式的结构性约束。

视频生成技术的成熟催生了另一条路线：以互联网规模视频与少量交互数据训练动作条件视频生成模型，再以模型预测控制驱动机器人。该路线的视觉保真度令人信服，但像素级生成的计算开销使长时程多步规划难以承受；评价体系以预测逼真度与视觉质量为主，规划能力缺少直接度量；像素目标迫使模型拟合场景中不可预测的高频细节，如草叶与树叶的精确位置，这些细节对决策没有贡献。

多模态大模型显著提升了视频语义理解与时序推理能力，语义能力并不等同于可用于控制的动力学模型。主流视频编码器普遍依赖语言监督以获得强表征，海量无语言标注视频的价值因此被大幅压缩。三条路线共同指向一个尚未被系统回答的问题：世界模型能否主要从观察中习得，并同时支撑理解、预测与规划。

联合嵌入预测架构（JEPA）为这一问题提供了理论切口。其主张不在像素空间重建未来，而在学到的表征空间中预测被遮蔽部分的表征，使模型编码场景中可预测、与决策相关的方面，回避不可预测的细节。I-JEPA 在图像域验证了该主张，V-JEPA 将其扩展到视频。两代模型受规模、数据量与片段时长制约，尚不足以承载通用世界模型；从无动作视频预训练过渡到动作条件规划，亦缺少完整路径。

V-JEPA 2 在这一脉络上给出系统性推进。预训练在超过 100 万小时互联网视频与 100 万张图像上完成，编码器规模达到 10 亿参数；理解与预测能力经注意力探针与语言模型对齐两条路径检验；冻结编码器后，仅以 62 小时无标注机

器人视频训练 3 亿参数的动作条件预测器 V-JEPA 2-AC，并在模型预测控制回路中以图像目标规划，于两个实验室的 Franka 机械臂上零样本完成抓取与拾放。该工作把“互联网视频承载世界先验、少量交互数据学习动作作用”的范式推进到可实证、可复现的程度。

二、研究内容

研究围绕一个核心命题展开：仅凭观察能否学得可用于规划的世界模型。命题被分解为表征、预测、规划三个递进层次，并落实为四项相互衔接的工作。

表征层的任务是规模化自监督视频预训练。数据侧整合 SSv2、Kinetics、HowTo100M、经检索式策展的 YT-Temporal-1B 与 ImageNet，构成约 2200 万样本、逾 100 万小时的 VideoMix22M；模型侧采用 ViT-g/16 编码器，以表征空间掩码去噪为目标训练，并系统考察数据规模、模型规模、训练步数与输入分辨率对表征质量的影响。

预测层的任务是在冻结表征之上检验未来状态预测能力。评估分两类：以 4 层注意力探针完成六项运动与外观分类任务，以 Epic-Kitchens-100 人类动作预判衡量时序预测；以 80 亿参数语言模型为解码端，检验视频表征在问答与时空推理任务上的可用性。

规划层的任务是把无动作表征转为动作条件世界模型。编码器保持冻结，在其表示之上训练 3 亿参数的 Transformer 预测器，以动作与末端执行器状态为条件自回归预测下一帧表征；规划在潜在空间完成，以图像子目标定义代价，在模型预测控制框架内滚动求解动作序列。

验证在真实机器人上闭环。训练仅使用 Droid 数据集的 62 小时无标注视频，不采集目标环境数据，不引入任务特定训练与奖励，在两个实验室的 Franka 机械臂上执行抓取与拾放，检验跨环境零样本迁移能力。

三、解决问题

真实交互数据稀缺，长期制约世界模型的规模化。该工作把数据来源从交互转向观察，让互联网视频承担世界如何演化的先验，交互数据只承担动作如何作用于表征的学习，数据瓶颈由交互规模转为视频规模。

视频生成式世界模型面临计算代价与像素细节的双重负担。表征空间预测以抽象表示替代逐像素生成，多步推演不必承担解码成本；预测目标集中于运动、物体与可供性等可预测成分，模型容量不再消耗于纹理噪声。

视频表征普遍被认为依赖语言监督。该工作以实验证明，未受语言监督预训练的编码器经对齐后，仍可在多个视频问答基准上达到同规模最优，为大规模无标注视频的利用提供了依据。

无动作视频与动作条件控制之间存在方法鸿沟。分阶段设计把问题解耦：动作无关预训练学习世界表征，动作条件后训练学习动作对表征的作用，两者以冻结编码器衔接，交互数据需求量降至小时级。

跨环境零样本规划缺少可行路径。潜在空间以图像子目标定义代价，模型预测控制在滚动时域内优化动作序列，奖励函数与任务特定训练被移除，系统在新环境中的行为由预训练先验与子目标共同决定。

四、技术方法

方法由表征预训练、能力读出与动作条件规划三段构成，前段决定表征质量，中段检验表征可用性，后段把表征接入决策。

表征预训练以表征空间掩码去噪为目标。给定掩码视图 x 与完整视图 y，编码器$E_{\theta(\cdot)}$提取 x 的表示，预测器$P_{\varphi(\cdot)}$结合可学习掩码标记 Δy 预测被遮蔽块的表示，以 L1 损失回归指数滑动平均编码器$E_{\theta}'(\cdot)$给出的目标，即最小化$\left\|P_{\varphi(\Delta y,E_{\theta(x)})}-sg\left(E_{\theta}'(y)\right)\right\|_1$，$sg(\cdot)$为停止梯度，损失仅作用于掩码块。EMA 目标与停止梯度的组合抑制表征坍缩，是十万至百万小时级训练得以稳定的前提。

架构采用视觉 Transformer。视频切分为 2×16×16 的管状块序列，多块掩码策略沿用 V-JEPA。位置编码使用三维旋转位置编码，特征维被划分为时间、高度、宽度三段并分别施加一维旋转；相较绝对 sincos 位置嵌入，3D-RoPE 在十亿参数规模下显著改善训练稳定性。

扩展由四项干预构成。数据由 200 万视频增至 2200 万，YT1B 经场景嵌入与聚类检索策展，剔除卡通与剪贴画内容；编码器由 ViT-L 的 3 亿参数扩至 ViT-g 的 10 亿参数；学习率采用 warmup-constant-decay 调度，迭代数由 9 万延至 25.2 万；预热与恒定阶段使用短片段与低分辨率，衰减阶段提升至 384 分辨率与 64

帧，以可控成本完成长视频高分辨率训练。

能力读出分两条路径。注意力探针冻结编码器，仅在表示上训练 4 层任务头，保证评估反映表征质量；语言对齐把视频编码器输出接入 80 亿参数语言模型，检验开放式语义与时序推理。

动作条件世界模型 V-JEPA2-AC 以冻结编码器为骨架，叠加 3 亿参数 Transformer 预测器。块因果注意力约束每个时间步只能关注当前与历史时间步的块特征、动作与末端执行器状态，模型以自回归方式预测下一帧表征。训练数据为 62 小时 Droid 机器人视频，优化在潜在空间进行，不涉及像素重建。

规划在潜在空间完成。图像子目标经编码器得到目标表征；模型预测控制在滚动时域内采样或优化动作序列，以 V-JEPA2-AC 前向预测状态表征，选取与目标表征距离最小的序列执行并滚动重规划。系统不依赖奖励函数与任务特定训练，感知输入仅为单目 RGB 图像。

五、实验分析

实验按表征、预测、语义、决策四个层次组织，证据由表征质量逐级推进到真实机器人行为，扩展性与数据策展作为支撑分析。

表征扩展的有效性以六项运动与外观分类任务的平均准确率度量。以 200 万视频预训练的 ViT-L/16 为基线，平均准确率为 84.2%。数据扩至 2200 万带来约 1.0 个百分点增益；模型扩至 10 亿参数再增约 1.5 个百分点；训练延至 25.2 万步再增约 0.8 个百分点；分辨率由 256 提升至 384、片段由 16 帧延至 64 帧后，平均准确率达到 88.2%，相对基线累计提升 4.0 个百分点。四项干预各自产生正向增益，视频自监督学习呈现与语言模型类似的规模效应。

运动理解与预测能力在两项基准上得到检验。Something-Somethingv2 上，V-JEPA2 以注意力探针取得 77.3%top-1 准确率，细粒度运动信息被有效编码；Epic-Kitchens-100 人类动作预判取得 39.7recall-at-5，相较此前最优模型相对提升约 44%。预测能力的增益与预训练规模同向变化，说明掩码去噪目标学到了可外推的动力学先验。

语义能力经语言对齐后评估。80 亿参数规模下，MVP 配对准确率 44.5，PerceptionTest 测试集准确率 84.0，TempCompass 多选准确率 76.9，

TemporalBench 短问答准确率 36.7，TOMATO 准确率 40.3，五项基准均达到同规模最优。结果的意义超出数值本身：未受语言监督的编码器经对齐即可与依赖语言监督的编码器竞争，视频表征必须依赖语言监督的假设由此被动摇。

决策能力在真实机器人上验证。V-JEPA2-AC 仅使用不超过 62 小时的 Droid 无标注视频训练，在两个实验室的 Franka 机械臂上以图像子目标规划，零样本完成抓取与拾放，可处理新物体与新环境；训练阶段未接触目标环境数据，未使用任务特定训练与奖励。该结果为“互联网视频预训练+小时级交互数据”的潜在世界模型规划提供了首个较为系统的真机证据。

数据策展与规模匹配构成支撑分析。对 YT1B 施加检索式策展带来约 1.4 个百分点提升；策展数据在小模型上即可接近完整 VideoMix22M 的效果，更大模型从多源混合数据获益更多。数据覆盖度与模型容量之间存在匹配关系，单一数据源难以支撑规模扩展。

评测视角的反思贯穿全文。既有视频世界模型研究以生成保真度与视觉质量为核心指标，以规划成功率、跨环境泛化与数据效率为核心的评测尚不充分。该工作以真实机器人任务作为最终检验，把“世界模型是否可用于决策”从主张转为可观测的行为证据。

六、结论

基于联合嵌入预测架构的自监督视频学习，足以构建兼具理解、预测与规划能力的世界模型。方法层面，表征空间掩码去噪目标与数据、模型、训练、分辨率四项扩展相互配合，将视频自监督预训练推进至 10 亿参数、百万小时数据量级；能力层面，所得表征在运动理解、动作预判与视频问答上达到领先水平，无需语言监督即可与语言模型有效对齐；应用层面，仅以 62 小时无标注机器人视频后训练的动作条件世界模型，即可在新环境的机械臂上零样本完成抓取与拾放。

该结果支持一个更为一般的判断：互联网视频承载世界如何演化的先验，少量交互数据只需学习动作如何作用于表征，世界模型因此可在数据效率与泛化能力之间取得新的平衡。这一判断为具身智能提供了一条可扩展、可复现的技术路线，也把世界模型研究的评价重心从生成质量移向决策效能。

七、优点分析

范式层面，该工作把世界模型的学习重心由交互数据与奖励转向观察数据，并给出可操作的工程路径：无动作预训练学习世界表征，动作条件后训练接入控制。相较端到端视觉—语言—动作模型，该路径把“世界如何演化”与“动作如何作用”解耦，数据需求结构因此改变。

方法层面，表征空间预测回避了像素级生成的算力开销与细节拟合，把模型容量集中到与决策相关的运动、物体与可供性信息；多步规划在潜在空间完成，滚动时域内的推演成本显著低于逐帧生成。EMA 目标、停止梯度与 3D-RoPE 的组合，为十亿参数规模的自监督视频训练提供了可复用的稳定性方案。

证据层面，论文构建了表征—语义—预测—决策四级证据链：注意力探针检验表征质量，语言对齐检验语义可用性，动作预判检验时序预测，真实机器人检验决策效能。能力主张沿证据链逐级收紧，结论的可检验性因此提高。

工程层面，数据全部取自公开来源，代码与模型权重开源，扩展要素逐项量化，实验具备较高可复现性；62 小时交互数据即可完成动作条件化的结果，对真实机器人数据昂贵的现实约束给出了直接回应。

八、不足分析

动作空间与平台覆盖有限。实验集中于单臂 Franka 机械臂的抓取式操作，动作维度与任务类型相对单一；双臂协调、移动操作、灵巧手与多机协作等设定尚未验证，方法在更高维动作空间上的可扩展性缺少证据。

规划仍依赖外部给定子目标。系统需要人工提供图像子目标，长时程任务分解与子目标生成未纳入方法闭环；模型预测控制虽以滚动重规划抑制偏差，预测器在长时程上的表征漂移、接触与形变等复杂物理现象的表达能力，仍缺少系统评估。

动作条件化属于有监督后训练。V-JEPA2-AC 依赖带动作标注的机器人数据，跨本体与跨数据分布的迁移能力尚不明确；目标平台与 Droid 分布差异较大时，性能可能显著下降。潜在空间规划的计算成本与控制频率之间亦存在张力，论文未系统报告规划耗时与成功率的权衡。

评测体系与规模门槛构成外部约束。视频世界模型缺少统一的、面向决策的基准，不同工作在数据、任务与指标上难以横向比较；本文任务数量与场景多样

性有限。10 亿参数编码器、百万小时视频与大规模算力对多数团队构成现实门槛，小规模条件下该方法是否仍具优势，论文讨论有限。语义能力部分来自语言模型侧的容量，视频表征本身的贡献仍需更细粒度分析。

九、研究启示

数据范式上，具身智能的瓶颈可以通过“观察数据规模化、交互数据轻量化”的方式缓解。构建高质量、可策展、合规的视频数据体系，其边际收益可能高于单纯扩大真机采集规模；数据策展对表征质量的影响在本文中已被量化，值得作为独立工程环节对待。

技术路线上，表征空间预测与像素空间生成服务于不同目标：前者面向决策，后者面向仿真与内容生成。算力受限条件下，优先发展面向决策的表征学习更为务实；表征预测与生成式模型的结合，则可能同时获得抽象能力与可解释的视觉推演。

评测导向上，世界模型的价值应由决策任务衡量。规划成功率、样本效率与跨环境泛化应成为基准的核心指标，生成保真度退居辅助位置；建立统一、可复现的决策导向评测，是该方向健康发展的基础设施。

研究组织上，本文“分阶段解耦、潜在空间规划、真实平台验证”的结构提供了可借鉴的模板：以公开数据与开源模型建立强表征基线，以小时级真机数据验证决策能力，以标准化指标闭环评估，在方法创新与工程可行性之间取得平衡。这一结构对资源有限的研究团队尤具参考价值。

研究方向上，研究方向大于方向错误的内卷。

十、论文精读图片证明（中文翻译版）

V-JEPA 2：自监督视频模型实现理解、预测与规划

***Mahmoud Assran*[1],•, *Adrien Bardes*[1],•, *David Fan*[1],•, *Quentin Garrido*[1],•, *Russell Howes*[1],•, *Mojtaba Komeili*[1],•, *Matthew Muckley*[1],•, *Ammar Rizvi*[1],•, *Claire Roberts*[1],•, *Koustuv Sinha*[1],•, *Artem Zholus*[1,2],•, *Sergio Arnaud*[1],•, *Abha Gejji*[1],•, *Ada Martin*[1],•, *Francois Robert Hogan*[1],•, *Daniel Dugas*[1],•, *Piotr Bojanowski1, Vasil Khalidov1, Patrick Labatut1, Francisco Massa1, Marc Szafraniec1, Kapil Krishnakumar1, Yong Li1, Xiaodong Ma1, Sarath Chandar2, Franziska Meier*[1],•, *Yann LeCun*[1],•, *Michael Rabbat*[1],•, *Nicolas Ballas*[1],•

[1]Meta FAIR, [2]Mila – 魁北克人工智能研究所与蒙特利尔理工学院
•核心团队

现代人工智能面临的一项重大挑战是学会理解世界并主要通过学习观察来采取行动（LeCun，2022）。本文探索了一种自监督方法，将互联网规模的视频数据与少量交互数据（机器人轨迹）相结合，以开发能够在物理世界中理解、预测和规划的模型。我们首先在包含超过100万小时互联网视频的视频和图像数据集上预训练了一个无动作联合嵌入预测架构——V-JEPA 2。V-JEPA 2在运动理解方面取得了强劲的性能（在Something-Something v2上达到77.3的top-1准确率），并在人类动作预测方面达到了最先进的性能（在Epic-Kitchens-100上达到39.7的recall-at-5），超越了此前针对特定任务的模型。此外，在将V-JEPA 2与大型语言模型对齐后，我们在80亿参数规模上展示了在多个视频问答任务上的最先进性能（例如，PerceptionTest上84.0，TempCompass上76.9）。最后，我们展示了如何通过使用来自Droid数据集的不到62小时未标注机器人视频，对一个潜在动作条件世界模型V-JEPA 2-AC进行后训练，从而将自监督学习应用于机器人规划任务。我们在两个不同实验室的Franka机械臂上零样本部署了V-JEPA 2-AC，并利用图像目标规划实现了物体的抓取和放置。值得注意的是，这一成果无需从这些环境中的机器人收集任何数据，也无需任何特定任务的训练或奖励。这项工作展示了如何从网络规模数据和少量机器人交互数据进行自监督学习，从而获得能够在物理世界中进行规划的世界模型。

日期：2025年6月13日
通讯作者：Nicolas Ballas <ballasn@meta.com> 和 Michael Rabbat <mikerabbat@meta.com>代码：https://github.com/facebookresearch/vjepa2 博客文章：https://ai.meta.com/blog/v-jepa-2-world-model-benchmarks

Meta

1 引言

人类在承担新任务和在陌生环境中操作时，具有适应和泛化的能力。若干认知学习理论表明，人类通过整合低层次的感觉输入来学习和表征、预测未来状态，从而学习一个关于世界的内部模型（Craik，1967；Rao and Ballard，1999），并且他们进一步假定，这一世界模型在任何给定时刻塑造着我们的感知，在塑造我们对现实的理解方面发挥着至关重要的作用（Friston，2010；Clark，2013；Nortmann et al.，2015）。此外，我们预测自身行为对世界未来状态影响的能力，对于目标导向的规划也是至关重要的（Sutton and Barto，1981，1998；Ha and Schmidhuber，2018；Wolpert and Ghahramani，2000）。构建能够从视频等感觉数据中学习世界模型的人工智能体，可以使它们理解物理世界、预测未来状态，并像人类一样在新情境中有效地进行规划，从而产生能够处理此前未曾遇到过的任务的系统。

先前的工作已经探索了从交互数据中构建预测性世界模型，这些数据由

V-JEPA 2 编码器，参数量高达 10 亿，并使用超过 100 万小时的视频进行训练。我们的实验证实，扩展自监督视频预训练可增强编码器实现视觉理解的能力，包括广泛的运动与外观识别能力，这通过基于探针的评估以及将编码器与语言模型对齐以进行视频问答来验证（Krojer 等，2024；Pătrăucean 等，2023；Liu 等，2024c；Cai 等，2024；Shangguan 等，2024）。

在互联网规模视频上完成预训练后，我们利用第一阶段学到的表征，在一小组交互数据上训练了一个动作条件世界模型 V-JEPA 2-AC。我们的动作条件世界模型是一个具有 3 亿参数的 transformer 网络，采用块因果注意力机制，以动作和先前状态为条件，自回归地预测下一视频帧的表征。仅使用来自 Droid 数据集（Khazatsky 等，2024）的 62 小时无标签交互数据，我们证明了训练潜在世界模型的可行性——该模型在给定子目标的情况下，可用于在 Franka 机械臂上规划动作，并在新环境中仅凭单目 RGB 相机零样本执行抓取式操作任务。

总之，我们证明，从视频中学习的联合嵌入预测架构可用于构建世界模型，使其能够理解物理世界、预测未来状态，并在新情境中有效规划；这是通过利用互联网规模视频和少量交互数据实现的。具体而言：

- 理解——基于探针的分类：扩展自监督视频预训练规模，可得到适用于众多任务的视频表征。V-JEPA 2 擅长编码细粒度运动信息，在需要运动理解的任务上表现强劲，例如 Something-Something v2，使用注意力探针达到 77.3 的 top-1 准确率。

- 理解——视频问答：V-JEPA 2 编码器可用于训练多模态大语言模型，以处理视频问答任务。我们在多个需要物理世界理解和时序推理的基准上，于 8B 语言模型级别观察到最先进的性能，例如 MVP（44.5 配对准确率）、PerceptionTest（84.0 测试集准确率）、TempCompass（76.9 多选准确率）、TemporalBench（36.7 多二分类短问答准确率）和 TOMATO（40.3 准确率）。特别地，我们表明，一个未经语言监督预训练的视频编码器可以与语言模型对齐并达到最先进的性能，这与传统观点相反（Yuan et al., 2025; Wang et al., 2024b）。

- 预测：大规模自监督视频预训练可增强预测能力。V-JEPA 2 使用注意力探针，在 Epic-Kitchens-100 人类动作预判任务上取得了最先进的性能，recall-at-5 达到 39.7，相比此前最佳模型相对提升了 44%。

- 规划：我们证明，V-JEPA 2-AC 仅使用来自常用 Droid 数据集的 62 小时无标注机器人操作数据进行后训练获得，便可部署到新环境中，利用给定子目标进行规划以求解抓取式操作任务。无需使用我们实验室机器人的任何额外数据进行训练，也无需任何任务特定训练或奖励，该模型便能在新环境中成功处理抓取式操作任务，例如对新物体的抓取和拾放。

本文的其余部分组织如下。第2节描述V-JEPA 2的预训练流程，包括使其能够超越Bardes等人（2024）原始V-JEPA方案进行扩展的关键要素。第3节介绍我们训练任务无关的动作条件世界模型V-JEPA 2-AC的方法，该方法利用预训练的V-JEPA 2模型。第4节展示通过基于模型的规划使用V-JEPA 2-AC进行机器人控制。由于V-JEPA 2-AC在学到的表示空间中建模世界动态，其能力从根本上取决于V-JEPA 2表示空间中所捕获的信息，因此我们进一步在第5节探讨V-JEPA 2在视频理解方面的性能，并在第6节探讨其在预测任务中的表现。最后，在第7节中我们展示V-JEPA 2可以与语言模型对齐以进行视频问答。第8节讨论相关工作，第9节进行总结。

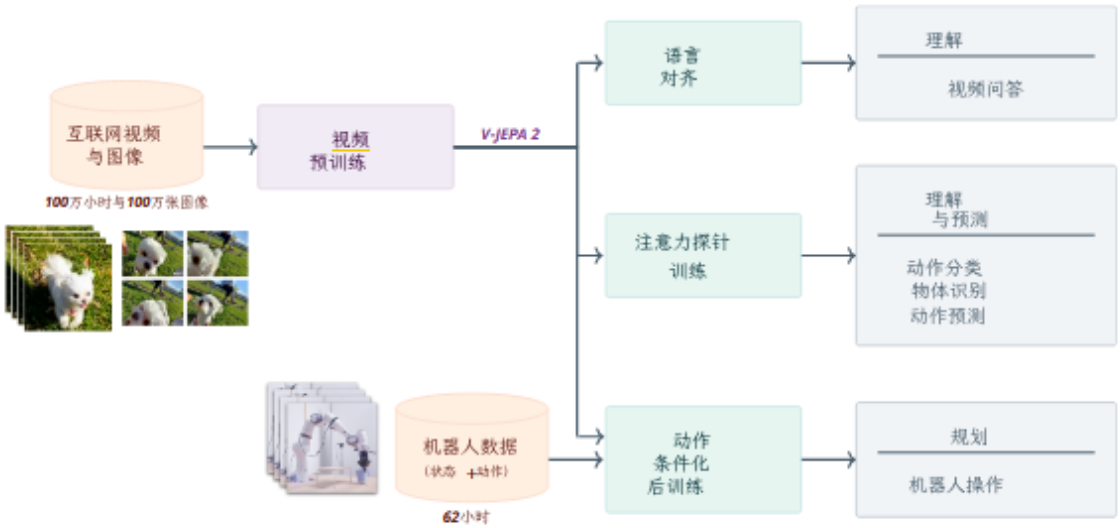


图1 V-JEPA 2概览。利用100万小时的互联网规模视频和100万张图像，我们使用视觉掩码去噪目标（Bardes et al., 2024; Assran et al., 2023）预训练V-JEPA 2视频模型，并通过将模型与LLM主干对齐，将该模型用于动作分类、物体识别、动作预测和视频问答等下游任务。预训练之后，我们还可以冻结视频编码器，并在学习到的表示之上，使用少量机器人交互数据训练一个新的动作条件预测器，并利用该动作条件模型V-JEPA 2-AC，在模型预测控制循环中通过规划来完成下游机器人操作任务。

然而，真实世界交互数据的有限可用性限制了这些方法的可扩展性。为解决这一局限，近期的工作利用互联网规模的视频和交互数据来训练动作条件视频生成模型以用于机器人控制，但在使用基于模型的控制进行机器人执行时仅展示了有限的结果（Hu et al., 2023; Yang et al., 2024b; Bruce et al., 2024; Agarwal et al., 2025）。特别是，这一研究方向往往侧重于评估预测的忠实性和视觉质量，而非规划能力，这或许是由于通过生成视频进行规划的计算成本所致。

在这项工作中，我们基于自监督假设，将其作为学习世界模型的一种手段，从而主要从观察中获取关于世界的背景知识。具体而言，我们利用联合嵌入预测架构（JEPA）（LeCun, 2022），它通过在学习到的表示空间中进行预测来学习。与专注于完全从交互数据中学习的方法相比，自监督学习使我们能够利用互联网规模的视频——这些视频描绘了状态序列，但没有对动作的直接观察——来学习表示视频观察，并在该学习到的表示空间中学习世界动态的预测模型。此外，与基于视频生成的方法相比，JEPA方法侧重于学习场景中可预测方面的表示（例如，运动物体的轨迹），同时忽略生成目标所强调的不可预测细节，因为生成目标进行像素级预测（例如，田野中每片草叶或树上每片叶子的精确位置）。通过扩展JEPA预训练，我们证明它可以产生具有最先进理解和预测能力的视频表示，并且这些表示可以作为动作条件预测模型的基础，并实现零样本规划。

我们的方法 V-JEPA 2 采用分阶段训练流程，首先在互联网规模视频上进行无动作预训练，随后使用少量交互数据进行后训练（见图 1）。在第一阶段，我们采用掩码去噪特征预测目标（Assran 等，2023；Bardes 等，2024），模型在学习到的表示空间中预测视频的被掩码片段。我们训练

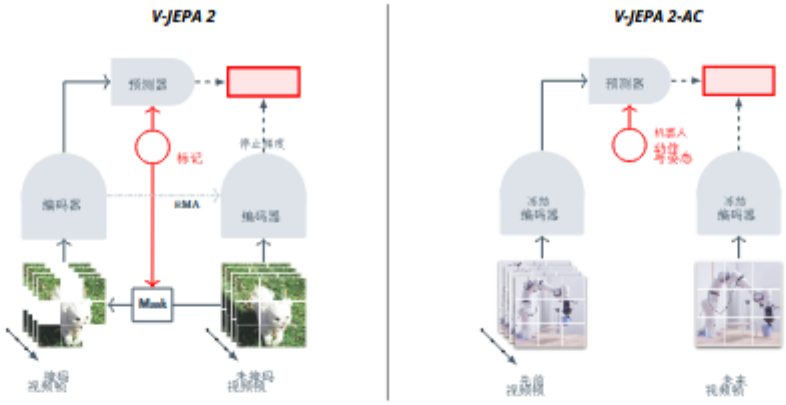


图2 多阶段训练。（左）我们首先使用视觉掩码去噪目标（Bardes et al., 2024; Assran et al., 2023）在互联网规模的图像和视频数据上预训练V-JEPA 2视频编码器。视频片段被划分为一系列token，并通过丢弃一部分token来施加掩码。编码器随后处理掩码后的视频序列，并为每个输入token输出一个嵌入向量。接下来，编码器的输出与一组指定掩码块位置的可学习掩码token拼接，随后由预测器处理。预测器的输出随后使用L1损失回归到预测目标。预测目标由ema编码器计算，其权重定义为编码器权重的指数移动平均值。（右）预训练之后，我们冻结视频编码器，并在学习到的表示之上学习一个新的动作条件预测器V-JEPA 2-AC。我们利用自回归特征预测目标，该目标涉及以过去的视频帧、动作和末端执行器状态为条件，预测未来视频帧的表示。我们的动作条件预测器使用块因果注意力模式，使得给定时间步的每个块特征可以关注当前及先前时间步的块特征、动作和末端执行器状态。

2 V-JEPA 2：扩展自监督视频预训练

我们在一个包含超过100万小时视频的视觉数据集上预训练V-JEPA 2。自监督训练任务基于表示空间中的掩码去噪，并建立在V-JEPA框架（Bardes等，2024）之上。在本文中，我们扩展了V-JEPA框架，探索了更大规模的模型，增加了预训练数据的规模，并引入了空间和时间渐进分辨率训练策略，使我们能够高效地预训练超出短16帧视频片段的模型。

2.1 方法

表示空间中的掩码去噪。V-JEPA 的目标是从视频的一个掩码视图 x 中预测其学习到的表示 y，即该视图中随机丢弃了部分图像块（图 2 左侧）。任务元架构由一个编码器 $E_\theta(\cdot)$ 和一个预测器 $P_\phi(\cdot)$ 组成，前者提取视频表示，后者预测被掩码视频部分的表示。编码器和预测器使用以下目标函数同时训练，

$$\text{minimize}_{\theta,\phi,\Delta_y} \quad \|P_\phi(\Delta_y, E_\theta(x)) - \text{sg}(E_{\bar{\theta}}(y))\|_1, \tag{1}$$

其中 Δ_y 是一个可学习的掩码标记，用于指示被丢弃图像块的位置。该损失使用停止梯度操作 sg(·) 以及编码器网络权重 θ 的指数移动平均 $\bar{\theta}$ 来防止表示坍缩。该损失仅应用于被掩码图像块的预测。

架构。编码器 $E_\theta(\cdot)$ 和预测器 $P_\phi(\cdot)$ 分别参数化为视觉变换器（Dosovitskiy 等人，2020）（即 ViT）。为了在视觉变换器中编码相对位置信息，我们采用 RoPE（旋转位置嵌入），而非 Bardes 等人所使用的绝对 sincos 位置嵌入。

（2024）。我们使用传统一维 RoPE（Su 等人，2024）的三维扩展，将特征维度划分为三个大致相等的段（分别对应时间、高度和宽度轴），并对每个轴的段分别应用一维旋转。我们发现，使用三维 RoPE 而非绝对 sincos 位置嵌入（Vaswani 等人，2017）有助于稳定最大模型的训练。为了使用我们的变换器编码器处理视频，我们首先将其分块为大小为 $2 \times 16 \times 16$（$T \times H \times W$）的管状体序列，并采用与 Bardes 等人（2024）相同的多块掩码策略。

关键扩展要素。在本节中，我们介绍并研究四项额外的关键要素，这些要素使得能够扩展 V-JEPA 预训练原则，从而获得我们的 V-JEPA 2 模型。

1. 数据扩展：我们通过利用和整理额外的数据源，将数据集规模从 200 万个视频增加到 2200 万个视频。
2. 模型扩展：我们将编码器架构从 3 亿参数扩展到超过 10 亿参数，从 ViT-L 升级到 ViT-g（Zhai 等，2022）。3. 更长训练：采用预热-恒定-衰减学习率调度简化了超参数调优，并使我们能够将训练从 9 万次迭代扩展到 25.2 万次迭代，有效利用额外数据。4. 更高分辨率：我们利用预热-恒定-衰减调度，通过在预热和恒定阶段训练更短、更低分辨率的视频片段，然后在最终衰减阶段增加分辨率和/或片段长度，从而高效扩展到更高分辨率的视频和更长的视频片段。

本节剩余部分将详细介绍上述每个组成部分，并使用接下来描述的评估协议量化每个组成部分的影响。

评估协议。我们进行模型预训练的目标是为编码器注入通用的视觉理解能力。因此，我们通过在六项运动和外观分类任务上评估模型所学表示的质量，来检验我们的模型和数据设计选择：Something-Something v2（Goyal等，2017）、Diving-48（Li等，2018）、Jester（Materzynska等，2019）、Kinetics（Kay等，2017）、COIN（Tang等，2019）和ImageNet（Deng等，2009）。我们采用冻结评估协议：冻结编码器权重，在其表示上训练一个任务特定的4层注意力探针来输出预测类别。本节主要关注六项理解任务的平均准确率。有关任务、评估协议和结果的更多细节，请参阅第5节。

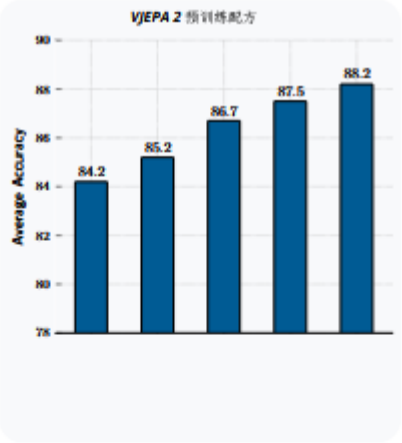


图3 扩展要素。以ViT-L/16模型为基线，扩展干预措施对6个图像和视频分类任务（SSv2、Diving-48、Jester、Kinetics、COIN、ImageNet）平均准确率的影响。

2.2 扩展自监督视频学习

我们首先概述扩展性分析的主要发现，其中我们研究了四个关键因素对下游任务平均性能的影响。图3展示了这些扩展干预对6个分类任务平均准确率的影响，基线是使用V-JEPA目标在200万视频上预训练的ViT-L/16模型。将数据集从200万扩展到2200万视频（VM22M）带来1.0个百分点的提升。将模型从3亿参数扩展到10亿参数

(ViT-g/16) 额外带来了 1.5 个百分点的提升。将训练从 90K 次迭代扩展到 252K 次迭代又贡献了 0.8 个百分点的改进。最后，在预训练和评估期间同时提升空间分辨率（$256 \rightarrow 384$）和时间时长（$16 \rightarrow 64$ 帧），将性能提升至 88.2%，这代表着相较于

表1 VideoMix22M（VM22M）预训练数据集。为构建我们的观测预训练数据集，我们整合了四种不同的视频来源和一个图像数据集。训练过程中，我们采用针对各来源的采样概率，并对YT1B应用基于检索的筛选，以减少噪声内容（如卡通或剪贴画风格）。

来源	样本	Type	总时长	是否应用筛选	权重
SSv2 (Goyal 等，2017)	**168K**	EgoVideo	**168**	**No**	**0.056**
Kinetics (Carreira 等，2019)	**733K**	ExoVideo	**614**	**No**	**0.188**
Howto100M (Miech 等，2019)	**1.1M**	ExoVideo	**134K**	**No**	**0.318**
YT-Temporal-1B（Zellers 等，2022）	**19M**	ExoVideo	**1.6M**	**Yes**	**0.188**
ImageNet（Deng 等，2009）	**1M**	图像	**n/a**	**No**	**0.250**

ViT-L/16 基线累计 4.0 个百分点的提升。每一项单独的改动都带来了积极影响，证实了视频自监督学习（SSL）中扩展的潜力。

2.3 预训练数据集

接下来，我们描述　构成我们预训练数据集的视频和图像来源，以及我们的方法
来整理数据　　**et.**

扩展数据集规模。我们通过组合公开可用的数据源来构建大规模视频数据集。在本工作中使用公开可用的数据源使其他研究人员能够复现这些结果。整体数据集包括来自 Goyal 等人（2017）提出的 Something-Something v2 数据集（SSv2）的自我中心视频、来自 Kinetics 400、600 和 700 数据集（Kay 等人，2017；Carreira 等人，2018，2019）的外中心动作视频、来自 HowTo100M（Miech 等人，2019）的 YouTube 教程视频，以及来自 YT-Temporal-1B（Zellers 等人，2022）的通用 YouTube 视频（我们称之为 YT1B）。我们还纳入了 ImageNet 数据集（Deng 等人，2009）中的图像，以增加预训练数据的视觉覆盖范围。为了实现图像和视频的联合预训练，我们将一张图像在时间上复制并视为一个 16 帧视频，其中所有帧都相同。在训练期间，我们以通过手动调优经验确定的加权系数从每个数据源中采样。最终得到的数据集（我们称之为 VideoMix22M，或 VM22M）包含 2200 万个样本。表 1 列出了这些数据源及其权重。

图4（左）比较了在VM22M上预训练的ViT-L/16与在Bardes等人（2024）较小（200万）的VideoMix2M数据集上训练的类似模型的性能。与VM2M相比，在VM22M上训练使视觉理解任务的平均性能提升了 **+1**个百分点。性能提升在基于外观的任务（如Kinetics-400、COIN和ImageNet）上更为显著，表明增加视觉覆盖对这些任务的重要性。

数据整理。YT1B是一个大型视频数据集，包含140万视频小时，与较小的视频数据集（如Kinetics和Something-Something v2）相比，没有经过整理且过滤极少。由于未整理和不平衡的数据可能会阻碍模型性能（Assran等人，2022；Oquab等人，2023），我们通过调整现有的基于检索的整理流程来处理视频，从而对YT1B进行过滤。具体而言，我们从YT1B视频中提取场景，为每个场景计算嵌入向量，然后使用基于聚类的检索过程（Oquab等人，2023）根据目标分布选择视频场景，该目标分布由Kinetics、Something-Something v2、COIN和EpicKitchen训练数据集组成。我们在附录A.2中描述了数据集构建过程的细节。与Oquab等人（2023）类似，我们确保目标验证集中的任何视频都不包含在初始的未整理数据池中。

在图4（右）中，我们比较了在未经整理的YT-1B数据上预训练的ViT-L模型与在我们的Curated-YT-1B数据集上训练的同类模型在视觉理解评估上的平均性能。使用整理后的数据集进行训练，相比未整理的基线模型平均性能提升了 **+1.4** 个百分点。值得注意的是，在ViT-L规模下，使用Curated-YT-1B训练的模型相对于完整的VM22M数据集取得了有竞争力的性能。然而，更大规模的模型从VM22M训练中获益更多（见附录A.2），这表明将Curated-YT-1B与其他数据源结合可以增强可扩展性。

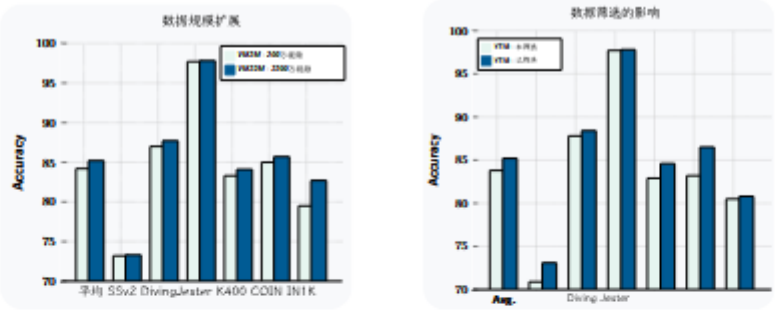


图 4 数据规模与筛选。我们在不同的数据混合上训练并比较模型。模型采用 ViT-L/16，遵循 Bardes 等人（2024）的方法，使用余弦学习率调度训练 90K 次迭代。（左）我们比较了在 VM2M 数据集和我们的 VM22M 数据集上预训练的 ViT-L/16 模型的性能。在 VM22M 数据集上训练使平均性能提升了 $+1$ 个百分点。在基于外观的任务（如 Kinetics-400、COIN 和 ImageNet）上，性能提升更为显著。（右）我们比较了在 YT1B 上预训练的 ViT-L/16 模型与在我们的 Curated-YT1B 数据集上预训练的模型的性能，后者利用了我们基于聚类的筛选方法。在筛选后的数据集上训练使平均性能提升了 $+1.4$ 个百分点，展示了数据筛选的有效性。

2.4 预训练方案

扩展模型规模。为了探索我们模型的扩展行为，我们训练了一系列编码器模型，参数量从3亿（ViT-L）到10亿（ViT-g）不等。所有编码器架构的详细信息见附录表12。注意，每个编码器使用相同的预测器架构，类似于ViT-small。我们在图5（左）中报告了这些编码器在视觉理解任务上的平均性能。将模型规模从3亿（ViT-L）扩展到10亿（ViT-g）参数，平均性能提升了 $+1.5$ 个百分点。运动和外观理解任务均从规模扩展中获益，其中SSv2提升了 $+1.6$ 个百分点，Kinetics提升了 $+1.5$ 个百分点（参见表4）。这些结果证实，自监督视频预训练能够有效利用更大的模型容量，直至10亿参数的ViT-g。

训练调度。V-JEPA 2 模型训练采用预热-恒定学习率调度，随后进入冷却阶段（Zhai et al., 2022; Hägele et al., 2024）。与 Hägele et al. (2024) 类似，我们发现该调度的性能与半余弦调度（Loshchilov and Hutter, 2016）相当；它还能使探索长训练运行更具成本效益，因为可以从恒定阶段的多个检查点启动多次冷却运行。我们简化了 Bardes et al. (2024) 的方案，保持固定的教师 EMA 和权重衰减系数，而非使用渐进式调度，因为这些变化对下游理解任务的影响极小。图 3 显示，将训练调度从 90K 迭代扩展到 252K 迭代，在 ViT-g 模型上带来了 $+0.8$ 的平均性能提升，验证了延长训练时长的收益。该调度还通过在冷却阶段逐步提高视频分辨率来促进渐进式训练。

高效的渐进分辨率训练。虽然大多数先前的视频编码器专注于16帧（约几秒）的短片段（Bardes et al., 2024; Wang et al., 2024b, 2023），我们探索了在更高空间分辨率下使用长达64帧（16秒）的较长片段进行训练。然而，训练时间会随着时长的增加和分辨率的提高而急剧增加——在 $64 \times 384 \times 384$输入上训练我们的ViT-g模型大约需要60个GPU年（见图5，中间）。为了减少这一开销，我们采用渐进分辨率策略（Touvron et al., 2019; Oquab et al., 2023），在保持下游性能的同时提升训练效率。我们的训练过程从一个预热阶段开始，在该阶段我们使用16帧、256×256分辨率的视频进行训练，并在12K次迭代中进行线性学习率预热，随后进入主训练阶段，以恒定学习率训练228K次迭代。然后，在冷却阶段，我们增加视频时长和分辨率，同时在12K次迭代中线性衰减学习率。因此，额外的

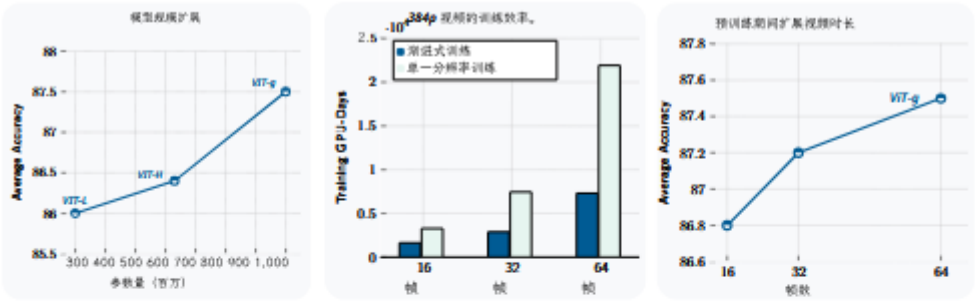


图 5 模型扩展。我们探索了模型规模和输入视频分辨率扩展的影响。所有模型均在 VideoMix22M 预训练数据集上训练。（左）六项理解任务的平均性能随模型规模的变化。模型以恒定学习率训练，直至下游任务性能趋于平稳。随后我们使用 256×256 分辨率的 64 帧对模型进行冷却，并报告冷却后的性能。将模型规模从 300M 扩展到 1B 参数可带来 $+1.7$ 个百分点的平均提升。（中）ViT-g 在 A100 GPU 上以 384×384 分辨率训练不同每片段帧数视频时的训练时间（GPU 天数）。我们将渐进分辨率训练（16 帧 / 256×256 分辨率下 252K 次迭代，随后在 384×384 分辨率下进行 12K 次冷却迭代）与全分辨率训练的预计时间进行比较。渐进训练可提供高达 $8\times$ 的加速，显著降低预训练计算需求。（右）冷却阶段增加视频时长对 ViT-g 下游性能的影响。即使在推理/评估时仅使用 16 帧片段，在训练的冷却阶段增加视频时长仍可使平均任务性能提升 $+0.7$ 个百分点。

与在更长时长、更高分辨率视频上训练相关的计算开销仅在最后的冷却阶段才会产生。这种方法能够实现高效的高分辨率训练：如图5（中间）所示，与在所有训练阶段从头直接以全分辨率训练此类模型相比，我们实现了GPU时间的 $8.4\times$ 缩减，且模型能够接收64帧、 384×384 分辨率的输入。此外，我们仍然观察到了能够处理更长时长和更高分辨率输入的模型所带来的优势，这将在下文讨论。

扩展时间和空间视频分辨率。图5考察了输入视频分辨率如何影响下游任务性能。当在预训练期间将片段时长从16帧增加到64帧，同时保持固定的16帧评估时长时，我们观察到平均性能提升了 $+0.7$ 个百分点（图5，右）。此外，我们发现评估期间增加视频时长和分辨率可在各项任务上带来显著提升（参见表4和附录A.4.2）。这些结果表明，视频自监督预训练在训练和评估期间均受益于时间分辨率的提高。尽管我们尝试扩展到更长的视频片段（128和256帧），但在这组理解任务上，我们未观察到超过64帧后的进一步提升。

3 V-JEPA 2-AC：学习动作条件世界模型

经过预训练后，V-JEPA 2 模型能够对视频中缺失的部分进行预测。然而，这些预测并未直接考虑智能体可能采取的动作所带来的因果效应。在本节所述的下一训练阶段中，我们专注于利用少量交互数据使模型可用于规划。为此，我们在冻结的 V-JEPA 2 视频编码器之上学习了一个帧因果的动作条件预测器（图 2 右侧）。我们使用 Droid 数据集（Khazatsky 等，2024）中的数据来训练模型，该数据集由通过遥操作采集的桌面 Franka Panda 机械臂实验数据组成。我们将由此得到的动作条件模型称为 V-JEPA 2-AC，并在第 4 节中展示 V-JEPA 2-AC 可在模型预测控制规划循环中使用，以在新环境中规划动作。

3.1 动作条件世界模型训练

我们的目标是利用预训练后的 V-JEPA 2 模型，获得一个潜在世界模型，使其可通过闭环模型预测控制用于具身智能体系统的控制。为实现这一目标，我们训练了 V-JEPA 2-AC，这是一个自回归模型，以控制动作和本体感知观测为条件，预测未来视频观测的表征。

在本节中，我们描述了该框架的一个具体实例，适用于配备固定外部视角相机的桌面机械臂，其中控制动作对应于末端执行器指令。该模型使用来自原始Droid数据集的约62小时无标签视频进行训练，该数据集由7自由度Franka Emika Panda机械臂（配备双指夹爪）的短视频组成，时长通常为3–4秒。此处，无标签视频指的是我们不使用额外的元数据来指示任何奖励、每次演示中执行的任务类型，或演示是否成功完成了所尝试的任务。相反，我们仅使用数据集中的原始视频和末端执行器状态信号（数据集中的每个视频都附带元数据，指示每一帧的末端执行器状态——三个维度表示位置，三个表示方向，一个表示夹爪状态）。

模型输入。在训练的每次迭代中，我们从 Droid 数据集中随机采样包含 4 秒视频片段的小批量数据，为简单起见，丢弃任何短于 4 秒的视频，从而得到一个更小的数据子集，包含不足 62 小时的视频。视频片段以分辨率256×256和每秒 4 帧（fps）的帧率采样，产生 16 帧的片段，表示为 $(x_k)_{k\in[16]}$，其中每个 x_k 表示单个视频帧。每次观测中机器人的末端执行器状态由序列 $(s_k)_{k\in[16]}$ 表示，其中 s_k 是相对于机器人基座定义的实值 7 维向量。s_k 的前三个维度编码末端执行器的笛卡尔位置，接下来的三个维度以外在欧拉角的形式编码其姿态，最后一个维度编码夹爪状态。我们通过计算相邻帧之间末端执行器状态的变化来构建动作序列 $(a_k)_{k\in[15]}$。具体而言，每个动作 a_k 是一个实值 7 维向量，表示帧 k 与 $k+1$ 之间末端执行器状态的变化。我们对采样的视频片段应用随机调整大小裁剪增强，宽高比在 (0.75, 1.35) 范围内采样。

损失函数。我们使用 V-JEPA 2 编码器 $E(\cdot)$ 作为图像编码器，对给定片段中的每一帧独立编码，以获得特征图序列 $(z_k)_{k\in[16]}$，其中 $z_k := E(x_k) \in \mathbb{R}^{H\times W\times D}$，$H \times W$ 表示特征图的空间分辨率，D 表示嵌入维度。在实践中，我们的特征图使用 ViT-g 编码器编码，形状为 $16 \times 16 \times 1408$。注意，在此后训练阶段编码器保持冻结。特征图序列、末端执行器状态和动作在时间上交错为 $(a_k, s_k, z_k)_{k\in[15]}$，并由 transformer 预测器网络 $P_\phi(\cdot)$ 处理，以获得下一状态表示预测序列 $(\hat{}z_{k+1})_{k\in[15]}$。标量值的教师强制损失函数最终计算为

$$\mathcal{L}_{\text{teacher-forcing}}(\phi) \coloneqq \frac{1}{T}\sum_{k=1}^{T}\|\hat{z}_{k+1} - z_{k+1}\|_1 = \frac{1}{T}\sum_{k=1}^{T}\left\|P_\phi\left((a_t, s_t, E(x_t))_{t\le k}\right) - E(x_{k+1})\right\|_1, \tag{2}$$

其中 $T = 15$。我们还计算两步 rollout 损失，以提高模型在推理时执行自回归 rollout 的能力。为简化表述并略微重载符号，令 $P_\phi(\hat{a}_{1:T},\ s_k,\ z_k) \in \mathbb{R}^{H\times W\times D}$ 表示通过从 $(s_k,\ z_k)$ 开始，以动作序列 $(\hat{a}_i)_{i\in[T]}$ 自回归运行 V-JEPA 2-AC 获得的最终预测状态表示。我们现在可以将 rollout 损失表示为：

$$\mathcal{L}_{\text{rollout}}(\phi) \coloneqq \|P_\phi(a_{1:T}, s_1, z_1) - z_{T+1}\|_1. \tag{3}$$

在实践中，我们使用 $T = 2$ 来计算展开损失，这样我们只通过一个循环步骤对预测器进行微分。

因此，总体训练目标由下式给出

$$L(\phi) \coloneqq \mathcal{L}_{\text{teacher-forcing}}(\phi) + \mathcal{L}_{\text{rollout}}(\phi), \tag{4}$$

并针对预测器权重 ϕ 进行最小化。为便于说明，图 6 中展示了训练过程，其中 $T = 4$ 同时用于教师强制和 rollout 损失。



图 6 V-JEPA 2-AC 训练。V-JEPA 2-AC 以自回归方式进行训练，采用教师强制损失和展开损失。（左）在教师强制损失中，预测器将当前帧表示的编码作为输入，并学习预测下一时间步的表示。（右）展开损失涉及将预测器的输出反馈作为输入，使模型能够被训练以预测未来多个时间步。通过优化这两个损失之和，V-JEPA 2-AC 减少了展开过程中的误差累积，从而增强了准确预测未来的能力。

架构。预测器网络 $P_\phi(\cdot)$ 是一个 ~300M 参数的 transformer 网络，具有 24 层、16 个头、1024 隐藏维度和 GELU 激活函数。输入到预测器的动作、末端执行器状态和展平特征图通过各自独立的可学习仿射变换进行处理，以将它们映射到预测器的隐藏维度。类似地，预测器最后一个注意力块的输出经过可学习仿射变换，以将它们映射回编码器的嵌入维度。我们使用我们的 3D-RoPE 实现来表示展平特征图中每个视频块的时空位置，同时仅对动作和姿态 token 应用时间旋转位置嵌入。我们在预测器中使用块因果注意力模式，使得给定时间步的每个块特征可以关注同一时间步的动作、末端执行器状态和其他块特征，以及来自先前时间步的这些特征。

3.2 通过规划推断动作

能量最小化。给定目标状态的图像，我们通过规划利用 V-JEPA 2-AC 完成下游任务。具体而言，在每个时间步，我们通过最小化目标条件能量函数，为固定时间范围规划一个动作序列。然后我们执行第一个动作，观察新状态，并重复该过程。令 s_k 表示当前末端执行器状态，x_k 和 x_g 分别表示当前观测帧和目标图像，它们分别通过视频编码器编码以获得特征图 z_k 和 z_g。给定规划范围 T，我们通过最小化目标条件能量函数来优化一系列机器人动作 $(a_t^*)_{t\in[T]}$

$$\mathcal{E}(\hat{a}_{1:T};\ z_k, s_k, z_g) := \|P(\hat{a}_{1:T}; s_k, z_k) - z_g\|_1, \tag{5}$$

使得 $(a_t^*)_{t\in[T]} := \text{argmin}_{\hat{a}_{1:T}}\ \mathcal{E}(\hat{a}_{1:T};\ z_k, s_k, z_g)$。如图7所示，模型通过选择一条轨迹来推断动作序列 $(a_t^*)_{t\in[T]}$，该轨迹使世界模型在未来 T 步的想象状态表示与其目标表示之间的L1距离最小化。在实践中，我们在每个

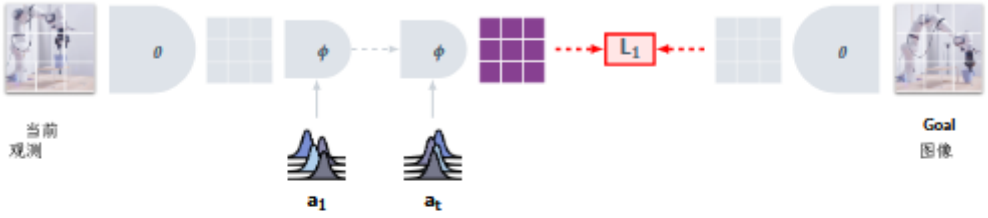


图 7 规划。我们为固定时间范围 T 规划动作序列，通过最小化世界模型在未来 T 步的想象状态表示与其目标表示之间的 L1 距离。L1 损失针对动作 $(a_k)_{k\in[T]}$ 使用交叉熵方法（Rubinstein，1997）进行优化。具体而言，在每个规划步骤中，我们从一系列初始化为零均值和单位方差的高斯分布中采样规划范围内每个点的动作坐标。前 k 个动作轨迹的种群统计量用于更新高斯分布的均值和方差。该过程重复若干次迭代，最终返回高斯序列的均值作为所选动作轨迹。

规划步骤中使用交叉熵方法（Rubinstein，1997）最小化(5)，并且如滚动时域控制那样，在重新规划之前仅执行机器人上的第一个动作。

4 规划：零样本机器人控制

本节我们展示如何使用 V-JEPA 2-AC 通过模型预测控制实现基本的机器人技能，如到达、抓取和拾放。我们专注于具有视觉目标规范的任务，并展示 V-JEPA 2-AC 能够零样本泛化到新环境。

4.1 实验设置

基线。我们将 V-JEPA 2-AC 的性能与两个基线进行比较，一个是通过行为克隆训练的视觉-语言-动作模型，另一个是基于视频生成的世界模型。

第一个基线基于 Octo 视频-语言-动作模型，该模型允许目标图像条件化（Octo Model Team et al., 2024）。我们从该模型 octo-base-1.5 版本的开源权重开始，该模型在包含超过100万条轨迹的 Open-X Embodiment 数据集上进行了预训练。[1] 我们使用事后重标记（Andrychowicz et al., 2017; Ghosh et al., 2019）以图像目标和末端执行器状态在整个 Droid 数据集上通过行为克隆微调 Octo 模型。具体而言，我们在训练期间从 Droid 数据集中采样随机轨迹片段，并均匀采样轨迹中最多向前20个时间步的目标图像。我们使用官方开源代码进行微调，包括所有标准 Droid 优化超参数，并利用 256×256 分辨率的单侧图像视图输入、两帧先前帧的上下文以及4个未来动作的预测范围。

我们对比的第二个基线基于 Cosmos 视频生成模型（Agarwal et al., 2025）。我们从无动作 Cosmos 模型（带有连续分词器的潜在扩散-7B 模型）的开源权重出发，该模型在 2000 万小时视频上训练，并使用官方发布的可动作条件微调代码在 Droid 上对该模型进行微调。[2] 为了提升在 Droid 上训练时的性能，我们（i）将学习率降低至与视频条件 Cosmos 方案中使用的学习率一致，（ii）移除了视频条件中的 dropout 以改善训练动态，以及（iii）将噪声水平提高了 e^2 倍，因为我们观察到使用较低噪声因子训练的模型难以利用条件帧中的信息。尽管 Cosmos 技术报告（Agarwal et al., 2025）

[1] 相比之下，我们在来自 Droid 的 23k 条轨迹（包括成功和失败）上训练 V-JEPA 2-AC。[2] https://github.com/nvidia-cosmos/cosmos-predict1

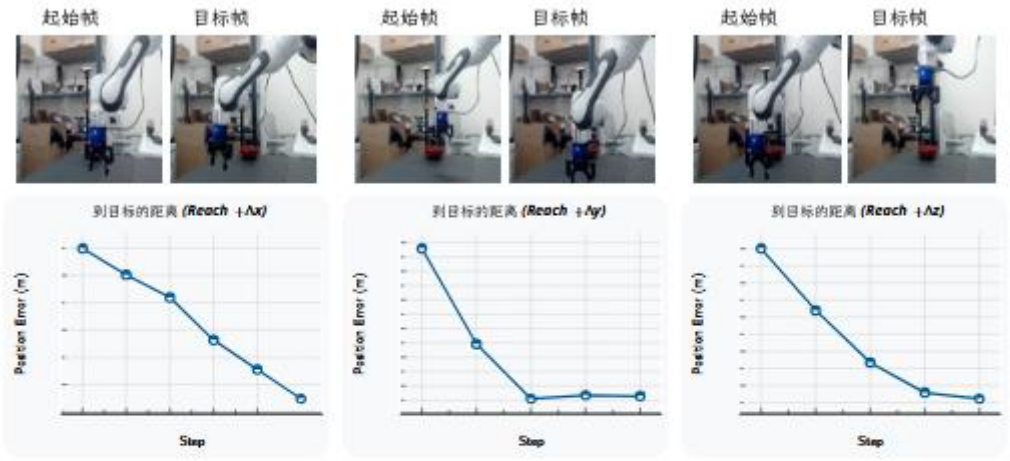


图 8 单目标到达。单目标到达是指根据单张目标图像将末端执行器移动到空间中期望位置的任务。该任务衡量模型对动作的基本理解以及对场景的三维空间理解（包括深度信息），输入来自单目 RGB 相机。在每一步中，我们使用 V-JEPA 2-AC 通过最小化模型想象未来状态表示与目标帧表示之间的 L1 距离来规划动作序列。随后执行第一个动作，并在下一时间步重新规划。在规划过程中，我们仅在以原点为中心、半径为 0.075 的 L1 球内采样单个动作。因此，单步内可实现的到目标笛卡尔距离的最大减少量为 0.13（~13cm）。

提到了将世界模型用于规划或模型预测控制作为未来应用，但据我们所知，这是首次报道的使用 Cosmos 模型进行机器人控制的尝试。

机器人部署。所有模型均以零样本方式部署在配备 RobotiQ 夹爪的 Franka Emika Panda 机械臂上，这些机械臂位于两个不同的实验室中，且均未出现在 Droid 数据集中。视觉输入通过未经校准的低分辨率单目 RGB 相机提供。机器人使用完全相同的模型权重和推理代码，以及基于操作空间控制的类似底层控制器。我们对 V-JEPA 2-AC 世界模型和 Cosmos 世界模型均采用阻塞控制（即系统等待上一条指令动作完成后才向控制器发送新动作），并对 Octo 同时实验了阻塞控制和非阻塞控制，报告两种方案中的最佳性能。使用 V-JEPA 2-AC 和 Cosmos 进行规划时，我们将每个采样动作约束在以原点为中心、半径为 0.075 的 L1 球内，这对应每个单独动作的末端执行器最大位移约为 13 cm，因为大幅动作对模型而言相对处于分布之外。

4.2 结果

单目标到达。首先，我们评估单目标到达任务，该任务涉及根据单个目标图像将末端执行器移动到空间中的期望位置。该任务衡量了对动作的基本理解，以及从单目RGB相机对场景的三维空间理解（包括深度）。

图8展示了在三个不同的单目标到达任务中，机器人执行过程中末端执行器与其目标位置之间的欧几里得距离。在所有情况下，模型能够将末端执行器移动到距其目标位置小于4厘米的范围内，并选择使误差单调递减的动作。这可以看作是一种视觉伺服（Hill, 1979），即利用相机的视觉反馈来控制机器人的运动。然而，与视觉伺服中的经典方法不同，V-JEPA 2-AC通过在没有标注的真实世界视频数据上进行训练来实现这一点。

在图 9 中，我们将公式 (5) 中 V-JEPA 2-AC 在 Δy reaching 任务上的能量景观可视化为

单个笛卡尔控制动作的函数，扫掠 Δx 和 Δy，同时保持 $\Delta z = 0$ 固定。能量函数在真实动作附近达到最小值，这进一步证明该模型已学会在没有精确传感的情况下合理推断动作的效果。同样有趣的是，V-JEPA 2-AC 诱导的能量景观相对平滑且局部凸，这应有助于规划。

抓取式操作。接下来，我们在更具挑战性的抓取式物体操作任务上评估所有模型，即抓取、持物到达和拾放。成功率报告在表 2 和表 3 中，并在 10 次试验中取平均值，试验间对任务进行了各种排列变化（例如物体位置、起始姿态等）。对于抓取和持物到达任务，模型仅接收单张目标图像。对于拾放任务，除最终目标外，我们还向模型提供两张子目标图像。第一张目标图像显示物体被抓取，第二张目标图像显示物体位于目标位置附近。模型首先针对第一子目标优化动作 4 个时间步，然后自动切换到第二子目标执行接下来 10 个时间步，最后切换到第三目标执行最后 4 个时间步。拾放任务的机器人执行示例如图 10 所示。Lab 1 中所有独立任务的起始帧和目标帧见附录 B.2。抓取任务需要基于视觉反馈的精确控制以正确抓握物体。持物到达任务要求模型在持物状态下导航，这需要具备对直觉物理的基本理解以避免掉落物体。最后，拾放任务测试组合这些原子技能的能力。

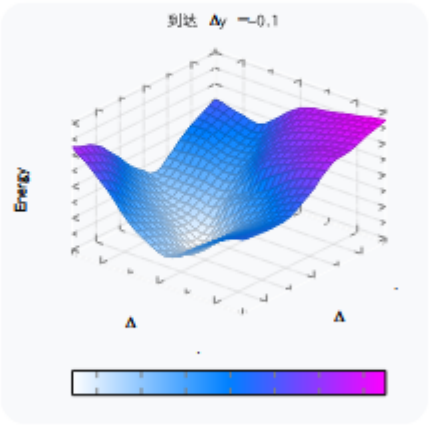


图 9 V-JEPA 2-AC 能量景观。针对单目标到达任务，末端执行器笛卡尔控制动作（扫掠 Δx 和 Δy，同时保持 $\Delta z = 0$固定）的能量景观：将目标图像与起始帧关联的真实动作位于 $(\Delta x, \Delta y) = (0, -0.1)$。我们可以看到，能量函数在 $(\Delta x, \Delta y) \approx (0, -0.05)$ 附近达到最小值，这表明模型已学会在无需精确传感的情况下合理推断动作效果。

虽然所有模型在抵达任务上均取得了较高的成功率，但在涉及物体交互的任务上，性能差异更为明显。我们观察到，所有模型的成功率均取决于所操作物体的类型。例如，我们发现杯子最容易抓取
方式是将一根手指伸入物体内部并沿杯沿握持，然而，如果模型产生的控制动作不够精确，机器人将错过杯沿而抓取失败。在操作盒子时，可行的抓取配置要多得多，但模型需要更精确的夹爪控制以确保手指张开得足够宽以抓取物体。我们发现，对于所有模型而言，成功率随物体类型的变化是由于次优动作与操作各物体所特有的挑战共同导致的。尽管如此，我们看到V-JEPA 2-AC模型在所有任务中取得了最高的成功率，凸显了潜在规划用于机器人操作的可行性。

在表 3 中，我们比较了使用 V-JEPA 2-AC 与基于潜在扩散的 Cosmos 动作条件视频生成模型时的规划性能。在两种情况下，我们都利用交叉熵方法（Rubinstein，1997）在单块 NVIDIA RTX 4090 GPU 上优化动作序列，并按照公式（5）通过将目标帧编码到模型的潜在空间中来构建能量函数。在使用 Cosmos 时，采用 80 个样本、10 个细化步骤和规划视野为 1 的设置，每个规划步骤中计算单个动作需要 4 分钟。虽然我们在使用 Cosmos 时在 reach 任务上达到了 80% 的高成功率，但在物体交互任务上的表现较弱。请注意，在每次动作规划时间为 4 分钟的情况下，完整的 pick & place 轨迹需要超过一小时的机器人执行时间。相比之下，在每个细化步骤中使用 $\mathbf{10\times}$ 更多样本时，V-JEPA 2-AC 世界模型每次动作仅需 16 秒，并在所有考虑的机器人技能上取得更高的性能。我们未来可以通过利用额外的计算资源进行规划来潜在地减少两种模型的规划时间，减少数量



图 10 拾取与放置。V-JEPA 2-AC 在多目标拾取与放置任务中的闭环机器人执行过程。高亮帧表示模型完成一个子目标并切换到下一个目标的时刻。第一个目标图像显示物体被抓住，第二个目标图像显示物体位于期望位置附近，第三个目标图像显示物体被放置在期望位置。模型首先针对第一个子目标优化动作 4 个时间步，然后自动切换到第二个子目标并持续接下来的 10 个时间步，最后在最后 4 个时间步切换到第三个目标。机器人动作通过目标条件规划推断。V-JEPA 2-AC 模型能够在不同实验室中的两条 Franka 机械臂上执行零样本拾取与放置任务，适应各种物体配置和杂乱环境。

表 2 零样本机器人操作。所有模型均以零样本方式部署在不同实验室的两台配备 RobotiQ 夹爪的 Franka 机械臂上。对于每个考虑的任务，给定图像目标，所有模型以闭环方式运行以推断实现目标的一系列动作。成功率基于 10 次试验报告，试验间对任务进行各种排列变化（例如物体位置、起始姿态等）。

			抓取		带物体接近		拾取与放置	
方法		接近	Cup	Box	Cup	Box	Cup	Box
Octo（Octo 模型团队等，2024）	实验室 1	100%	20%	0%	20%	70%	20%	10%
	实验室 2	100%	10%	0%	10%	70%	10%	10%
	Avg	*100%*	*15%*	*0%*	*15%*	*70%*	*15%*	*10%*
V-JEPA 2-AC（我们的方法）	实验室 1	100%	70%	30%	90%	80%	80%	80%
	实验室 2	100%	60%	20%	60%	70%	80%	50%
	Avg	*100%*	*65%*	*25%*	*75%*	*75%*	*80%*	*65%*

每个时间步所使用的样本数量和细化步骤、在世界模型的想象中训练前馈策略以初始化规划问题，或者在 V-JEPA2-AC 的情况下利用基于梯度的规划。

4.3 局限性

对相机位置的敏感性。由于 V-JEPA 2-AC 模型经过训练，在给定末端执行器笛卡尔控制动作的情况下预测下一视频帧的表示，且没有任何显式的相机标定，因此它必须从单目 RGB 相机输入中隐式地推断动作坐标轴。然而，在许多情况下，机器人基座在相机视野中不可见，因此推断动作坐标轴的问题定义不明确，导致世界模型出现误差。在实践中，我们手动尝试了不同的相机位置，最终确定了一个在我们所有实验中均表现良好的位置。我们在附录 B.4 中对 V-JEPA 2-AC 世界模型对相机位置的敏感性进行了定量分析。

长程规划。使用世界模型进行长程规划受到若干因素的限制。首先，自回归预测存在误差累积问题：表示空间的准确性

表3 规划性能。比较使用MPC结合V-JEPA 2-AC世界模型与Cosmos世界模型进行闭环机器人操作的表现。在两种情况下，我们均利用交叉熵方法（Rubinstein，1997）在单块NVIDIA RTX 4090 GPU上优化动作序列。对于每项机器人技能，我们在10个任务上评估每个模型并取平均值。在80个样本、10次细化步骤和规划时域为1的设置下，使用Cosmos（一种基于潜在扩散的动作条件视频生成模型）在每个规划步骤中计算单个动作需要4分钟。请注意，在每次动作规划时间为4分钟的情况下，一个完整的抓取与放置轨迹需要超过一小时。相比之下，V-JEPA 2-AC世界模型在每次细化步骤中使用 **10×** 更多样本，每次动作仅需16秒，并在所有考虑的机器人技能上取得更高的性能。

实验 2	规划细节					抓取		拾取与放置	
方法	#样本数	迭代	视界	Time	到达	Cup	Box	Cup	Box
Cosmos（Agarwal 等，2025）	**80**	**10**	**1**	4 分钟	**80%**	**0%**	**20%**	**0%**	**0%**
V-JEPA 2-AC（ours）	**800**	**10**	**1**	16秒。	**100%**	**60%**	**20%**	**80%**	**50%**

预测能力随着自回归推演步数的增加而下降，从而使长时程的可靠规划变得更加困难。其次，长时程规划扩大了搜索空间：在规划时程线性增加的情况下，可能的动作轨迹数量呈指数增长，从而使长时程规划在计算上面临挑战。另一方面，长时程规划对于解决非贪心预测任务（例如无图像子目标的拾取与放置）是必要的。未来探索用于长时程规划的世界模型将使得解决更多复杂且有趣的任务成为可能。

图像目标。遵循目标条件机器人操作领域的许多先前工作（Finn and Levine，2017；Lynch et al.，2020；Chebotar et al.，2021；Jang et al.，2022；Liu et al.，2022；Gupta et al.，2022），我们当前的优化目标公式假设可以获取视觉目标。然而，在真实环境中部署机器人时，以其他形式（例如语言）表达目标可能更为自然。将潜在动作条件世界模型与语言模型相对齐的未来工作，将朝着通过自然语言进行更通用任务指定的方向迈进。

5 理解：基于探针的分类

表示空间世界模型（如上文讨论的 V-JEPA 2-AC）的能力本质上受限于所学表示空间中编码的状态信息。在本节及后续章节中，我们通过探针方法探测 V-JEPA 2 所学到的表示，并在视觉分类任务上将 V-JEPA 2 编码器与其他视觉编码器进行比较。

视觉分类任务可以侧重于外观理解或运动理解。外观理解任务通常可以利用输入视频片段中单帧可见的信息来解决（即使分类标签描述的是动作），而运动理解任务则需要多帧信息才能正确分类视频（Goyal et al.，2017）。为确保对运动和外观两方面的平衡评估，我们选择了三个运动理解任务，即 Something-Something v2（SSv2）、Diving-48 和 Jester，这些任务要求模型理解人类手势和动作。对于外观理解，我们选择了 Kinetics400（K400）、COIN 和 ImageNet（IN1K），这些任务涉及识别动作、场景和物体。实验表明，V-JEPA 2 在运动理解任务上优于最先进的视觉编码器，同时在外观理解任务上具有竞争力。

注意力探针。我们在冻结的编码器输出之上，使用每个任务的训练数据训练一个4层注意力探针。我们的注意力探针由四个transformer块组成，其中最后一个块使用可学习的查询token将标准自注意力替换为交叉注意力层。按照标准做法，在推理过程中从视频中采样若干具有固定帧数的片段，然后对所有片段的分类logits取平均值。我们保持与V-JEPA 2预训练时相似的分辨率。我们在附录C.2中对注意力探针的层数进行了消融实验，并提供了下游任务中使用的片段数、片段大小及其他超参数的完整细节。

表4 动作与物体分类。我们报告了V-JEPA 2模型在动作和物体分类任务上的分类性能，所有模型均在分辨率 256×256 下使用64帧进行预训练，但V-JEPA 2 ViT-g_{384} 在分辨率384×384下预训练，并将其性能与最先进的图像和视频编码器进行比较。除V-JEPA 2 ViT-g_{384}外，所有模型遵循相同的评估协议。对于SSv2，我们使用 256×256 分辨率和 $16 \times 2 \times 3$ 输入（16帧片段，2个时间裁剪，3个空间裁剪），K400使用 $16 \times 8 \times 3$，COIN使用 $32 \times 8 \times 3$，Diving-48和Jester使用 $32 \times 4 \times 3$。V-JEPA 2 ViT-g_{384} 在所有六个任务上使用更高的 384×384 分辨率，并且对SSv2额外使用 $64 \times 2 \times 3$ 输入，对COIN使用32x8x3输入。我们的V-JEPA 2 ViT-g在运动理解任务上显著优于其他视觉编码器，在外观任务上具有竞争力。它在所有图像和视频编码器中取得了最佳的平均性能87.5。V-JEPA 2 ViT-g_{384} 在各任务上进一步提升结果，达到88.2的平均性能。 *：PE_{coreG}使用注意力探针和448px的输入分辨率在ImageNet上达到89.8%的准确率（Bolya et al., 2025）。在我们的情况下，我们使用256px的输入分辨率和不同的探针架构。

			运动理解			外观理解		
方法	参数	Avg.	SSv2	*Diving-48*	*Jester*	K400	COIN	IN1K
文献中报告的结果								
VideoMAEv2 (Wang 等，2023)	1B	–	56.1	–	–	82.8	–	71.4
InternVideo2-1B (Wang 等，2024b)	1B	–	67.3	–	–	87.9	–	–
InternVideo2-6B (Wang 等，2024b)	6B	–	67.7	–	–	88.8	–	–
VideoPrism (Zhao 等，2024)	1B	–	68.5	71.3	–	87.6	–	–
使用相同协议评估的图像编码器								
DINOv2 (Darcet 等人，2024)	1.1B	81.1	50.7	82.5	93.4	83.6	90.7	86.1
PE_{coreG} (Bolya 等，2025)	1.9B	82.3	55.4	76.9	90.0	88.5	**95.3**	87.6*
SigLIP2 (Tschannen 等，2025)	1.2B	81.1	49.9	75.3	91.0	87.3	95.1	**88.0**
使用相同协议评估的视频编码器								
V-JEPA ViT-H (Bardes 等，2024)	600M	85.2	74.3	87.9	97.7	84.5	87.1	80.0
InternVideo2_{s2}-1B (Wang 等，2024b)	1B	87.0	69.7	86.4	97.0	**89.4**	93.8	85.8
V-JEPA 2 ViT-L	300M	86.0	73.7	89.0	97.6	85.1	86.8	83.5
V-JEPA 2 ViT-H	600M	86.4	74.0	89.8	97.7	85.3	87.9	83.8
V-JEPA 2 ViT-g	1B	87.5	75.3	90.1	97.7	86.6	90.7	84.6
V-JEPA 2 ViT-g_{384}	1B	**88.2**	**77.3**	**90.2**	**97.8**	87.3	91.1	85.1

评估方案。我们在运动任务和外观任务上将 V-JEPA 2 的性能与其他若干视觉编码器进行比较：带寄存器的 DINOv2 （Darcet 等，2024）是当前图像自监督学习的最先进模型，而 SigLIP2 （Tschannen 等，2025）和感知编码器 PE_{coreG}（Bolya 等，2025）是图像-文本对比预训练的两个最先进模型。我们还考虑了两个视频编码器：自监督的 V-JEPA（Bardes 等，2024），以及主要依赖视觉-文本对比预训练的 InternVideo2_{s2}-1B（Wang 等，2024b）。

我们对每个基线模型和 V-JEPA 2 采用相同的评估协议，在冻结编码器之上学习一个注意力探针，类似于 Bardes 等人（2024）的做法。我们按照 Oquab 等人（2023）使用的流程将基于图像的模型适配到视频，拼接每个输入帧的特征。对于 InternVideo2_{s2}-1B，我们在 ImageNet 任务中使用其图像位置嵌入，对于视频任务，我们将其位置嵌入从 4 帧插值到 8 帧，产生与 V-JEPA 2 相似的 token 数量。尽管使用相同的评估协议，基线编码器在不同的数据上训练（例如，DINOv2 在 LVD-142M 上，PE_{coreG} 在 MetaCLIP 上），因此不能直接比较。因此，我们只能在系统层面比较不同的方法：即在训练协议和数据存在差异的情况下，使用一致的评估协议进行比较。我们还纳入了文献中使用类似冻结协议但可能具有不同注意力头架构的现有结果。特别是，我们分享了 VideoMAEv2（Wang 等人，2023）、InternVideo-1B 和 6B（Wang 等人，2024b）以及 VideoPrism（Zhang 等人，2024c）在我们所考虑的分类任务上的已报告结果（如有）。我们在附录 C.1 中提供了完整的评估和超参数。

结果。表4报告了V-JEPA 2、我们评估的其他编码器以及文献中报告的其他显著结果的分类性能。V-JEPA 2 ViT-g（256分辨率）在运动理解任务上显著优于其他视觉编码器。它在SSv2上达到了75.3的top-1准确率，相比之下

表 5 预测：人类动作预期。在 EK100 动作预期基准上与最先进方法进行比较。我们报告了在 EK100 验证集上动词、名词和动作的平均类别 recall-at-5。V-JEPA 2 的性能随模型规模线性扩展，并在所有模型规模上超越了此前的最先进水平。

方法	参数量	动作预期		
		Verb	Noun	动作
InAViT（Roy 等，2024）	160M	51.9	52.0	25.8
Video-LLaMA（Zhang 等，2023）	7B	52.9	52.0	26.0
PlausiVL（Mittal 等，2024）	8B	55.6	54.2	27.6
冻结骨干网络				
V-JEPA 2 ViT-L	300M	57.8	53.8	32.7
V-JEPA 2 ViT-H	600M	59.2	54.6	36.5
V-JEPA 2 ViT-g	1B	61.2	55.7	38.0
V-JEPA 2 ViT-g_{384}	1B	**63.6**	**57.1**	**39.7**

InternVideo为69.7，$PE_{Core}G$为55.4。V-JEPA 2在外观任务上也具有竞争力，在ImageNet上达到84.6（相比V-JEPA提升了 +4.6 个百分点）。总体而言，与其他视频和图像编码器相比，V-JEPA 2在所有六项任务上获得了最佳的平均性能。更高分辨率、更长时长的V-JEPA 2 ViT-g_{384} 在所有任务上展现出进一步提升，达到88.2的平均性能。

6 预测：基于探针的动作预判

动作预判是指在动作发生前某一时刻，根据上下文视频片段预测未来动作。使用 Epic-Kitchens-100（EK100）基准（Damen 等，2022），我们证明 V-JEPA 2 的动作预判性能随模型规模增大而持续提升。此外，尽管仅使用在 V-JEPA 2 表示之上训练的注意力探针，我们仍表明 V-JEPA 2 显著优于先前专为此任务设计的最先进方法。

任务。EK100 数据集包含 100 小时的烹饪活动，以第一人称视角在 45 个厨房环境中录制。EK100 中的每个视频都标注了动作片段，包括开始时间戳、结束时间戳和动作标签。共有 3,568 个唯一动作标签，每个标签由一个动词和一个名词类别组成，总计 97 个动词类别和 300 个名词类别。EK100 动作预判任务涉及从动作片段开始时间戳之前出现的视频片段（称为上下文）中预测名词、动词和动作（即联合预测动词和名词）。上下文结束与动作片段开始之间的间隔为预判时间，默认设置为 1 秒。鉴于给定上下文可能存在不同的未来动作，采用平均类别召回率-at-5 作为衡量性能的指标（Damen 等，2022）。

预测探针。在冻结的V-JEPA 2编码器和预测器之上训练一个注意力探针，以预测未来动作。具体而言，我们采样一个在动作开始前1秒结束的视频片段。该视频上下文被输入V-JEPA 2编码器。预测器接收编码器表示，以及对应于未来1秒帧的掩码标记，并预测未来视频帧的表示。预测器和编码器的输出沿标记维度拼接，并输入到一个注意力探针中，其架构与第5节中使用的类似，不同之处在于预测探针的最终交叉注意力层学习三个查询标记（而非一个），每个查询输出被馈送到不同的线性分类器，分别预测动作类别、动词类别和名词类别。对每个分类器独立应用焦点损失（Lin等，2017），然后在通过探针的共享注意力块反向传播之前求和。我们在附录D.1中提供了额外细节和评估超参数。

基线方法。我们将我们的模型与三个专门为动作预判训练的基线方法进行比较：InAViT（Roy 等，2024）是一种监督方法，利用显式的手物交互建模，



图11 EK100预测可视化。（左）：从上下文帧中选取的四帧。（中）：模型预测，按可能性排序。（右）：1秒预期时间之后的后续帧。我们展示了两个模型成功的示例和一个模型失败的示例。

而 Video-LLaMA（Zhang 等，2023）和 PlausiVL（Mittal 等，2024）都是利用大语言模型的方法，参数量高达 70 亿。

结果。表5总结了在EK100动作预测基准上的结果。我们比较了V-JEPA 2 ViT-L、ViT-H和ViT-g编码器，参数量从3亿增加到10亿。三者均利用32帧、每秒8帧、分辨率为 $\mathbf{256 \times 256}$ 的视频上下文。我们还报告了使用分辨率 $\mathbf{384 \times 384}$的ViT-g_{384} 的结果。V-JEPA 2在动作预测recall-at-5方面展现出相对于模型规模的线性扩展行为。参数量为3亿的V-JEPA 2 ViT-L达到32.7的recall-at-5。将模型规模增大到10亿参数后，recall-at-5提升了 $\mathbf{+5.3}$ 个百分点，达到38.0。此外，V-JEPA 2受益于使用更高分辨率的上下文，分辨率为 $\mathbf{384 \times 384}$ 的V-JEPA 2 ViT-g_{384} 相比使用 $\mathbf{256 \times 256}$ 分辨率的其他模型，recall-at-5进一步提升了 $\mathbf{+1.7}$ 个百分点。

V-JEPA 2 显著超越了先前的最先进模型 PlausiVL，即便其参数量仅为 3 亿，而 PlausiVL 使用了 80 亿参数。具体而言，V-JEPA 2 ViT-g_{384} 在动作 recall-at-5 指标上相较 PlausiVL 展现出 $\mathbf{+12.1}$ 个百分点的提升，对应 44% 的相对改进。

在图 11 中，我们可视化了 V-JEPA 2 对 EK100 验证集三个样本的预测，其中两个样本模型预测成功，一个样本模型预测失败。对于两个成功示例，V-JEPA 2 不仅以 top-1 置信度正确检索到正确动作，还能基于给定上下文提出连贯的 top-2 至 top-5 动作。例如，在顶行中，正确动作是"洗水槽"，但考虑到水龙头和墙壁的存在，"打开水"或"清洁墙壁"也都会是合理的动作。模型还预测了"冲洗海绵"，这是当前正在执行的动作，可能是假设该动作在 1 秒后仍可能持续。对于失败案例，V-JEPA 2 仍然提出了连贯的动作，如"关门"和"放下香料包"，但错过了物体的确切性质："茶包"。

局限性。V-JEPA 2 和 EK100 基准存在若干局限性。首先，V-JEPA 2 并未完全解决 EK100，存在模型在动词、名词或两者上均预测错误的失败案例。我们在附录 D.2 中研究了这些失败的分布。其次，我们在此聚焦于以 1 秒预见时间预测动作。当在更长的时间跨度上预测时，V-JEPA 2 的准确率会下降，见附录 D.2。第三，EK100 基准仅限于厨房环境，词汇封闭且定义明确，我们尚不清楚 V-JEPA 2 对其他环境的泛化能力如何。这限制了在 EK100 上训练的模型的实用性和适用性。最后，EK100 中的动作选自固定的类别集合，因此无法泛化到训练集中不存在的动作类别。

7 理解：视频问答

在本节中，我们探索 V-JEPA 2 执行开放语言视频问答（VidQA）的能力。为实现语言能力，我们采用由 LLaVA 系列模型（Li et al., 2024b）推广的非 token 化早期融合（Wadekar et al., 2024）方案，以 V-JEPA 2 作为视觉编码器来训练多模态大语言模型（MLLM）。在这类 MLLM 中，通过将视觉编码器的输出 patch 嵌入投影到 LLM 的输入嵌入空间，使视觉编码器与大语言模型对齐。随后，MLLM 要么进行端到端训练，要么在冻结视觉编码器的情况下训练。用于 VidQA 的 MLLM 中所使用的大多数编码器通常是图像编码器，它们对视频输入逐帧独立应用（Qwen Team et al., 2025; Zhang et al., 2024b）。此类编码器的常见实例包括 CLIP（Radford et al., 2021）、SigLIP（Tschannen et al., 2025）和 Perception Encoder（Bolya et al., 2025），选择它们主要是因其与语言的语义对齐，这种对齐通过图像-字幕对预训练获得。据我们所知，我们的工作是首个使用未经任何语言监督预训练的视频编码器来训练用于 VidQA 的 MLLM 的工作。

MLLM 在下游任务上的性能也高度依赖于对齐数据。在这些实验中，我们使用了一个包含 8850 万个图像-文本对和视频-文本对的数据集，与用于训练 PerceptionLM（Cho et al., 2025）的数据集类似。为了展示 V-JEPA 2 编码器的有效性，我们首先在 7.2 节中使用 1800 万个样本的子集，在受控数据设置下将 V-JEPA 2 与其他最先进的视觉编码器进行比较。然后，在相同的受控设置下，我们在 7.3 节中展示，扩大视觉编码器和输入分辨率均能持续提升 VidQA 性能。最后，我们在 7.4 节中扩大对齐数据规模，使用全部 8850 万个样本，以测试 V-JEPA 2 在语言对齐方面的极限。我们的结果表明，在受控数据设置下，V-JEPA 2 在开放式 VidQA 任务上相比其他视觉编码器取得了有竞争力的性能。在扩大对齐数据后，V-JEPA 2 在多个 VidQA 基准上达到了最先进的性能。

7.1 实验设置

视频问答任务。我们在 PerceptionTest（Pătrăucean 等，2023）上进行评估，该基准测试模型在记忆、抽象、物理和语义等不同技能方面的表现。此外，我们在 MVP 数据集（Krojer 等，2024）上进行评估以考察物理世界理解能力，该数据集采用最小视频对评估框架来缓解文本和外观偏见。我们还分别在 TempCompass、TemporalBench 和 TOMATO（Liu 等，2024c；Cai 等，2024；Shangguan 等，2024）上进行评估，以研究模型的时间理解和记忆能力。最后，我们使用 MVBench（Li 等，2024c）报告通用理解能力的结果，该基准偏向单帧外观特征（Krojer 等，2024；Cores 等，2024），并使用 TVBench（Cores 等，2024）报告结果，该基准在文献中被提出作为通用和时间理解的替代方案，以缓解上述偏见。

视觉指令调优。为在视觉问答任务上评估 V-JEPA 2 表征，我们采用 LLaVA 框架（Liu et al., 2024a）中的视觉指令调优流程，将 V-JEPA 2 与 LLM 对齐。该过程使用可学习的投影模块（通常为 MLP）将视觉编码器输出（或视觉 token）转换为 LLM 输入。我们遵循 Liu et al. (2024b) 的方法，通过渐进式三阶段流程训练 MLLM：阶段 1，仅使用图像描述数据训练投影模块；阶段 2，在大规模图像问答数据上训练完整模型；阶段 3，进一步在大规模视频描述和问答数据上训练模型。通过这种分阶段训练方式，LLM 逐步提升对视觉 token 的理解能力。视觉编码器可以冻结，也可以与 MLLM 其余部分一同微调。我们探索了这两种设置：冻结视觉编码器能更清晰地反映视觉特征的质量，而微调视觉编码器则能获得更好的整体性能。视觉指令训练的更多细节见附录 E。

7.2 与图像编码器的比较

为了分离视觉编码器对 MLLM 性能的贡献并与 V-JEPA 2 进行比较，我们引入了一个受控设置：我们使用不同的最先进编码器分别训练各个 MLLM，采用

表 6 现成图像编码器与 V-JEPA 2 在冻结编码器设置下的比较。所有实验使用相同的 LLM 主干（Qwen2-7B-Instruct）、数据和训练设置，且视觉编码器保持冻结。PerceptionTest 准确率报告的是 SFT 后的验证集结果。

方法	参数量 编码器 / LLM	Avg.	PerceptionTest SFT / Acc	MVP Paired-Acc	TempCompass multi-choice	TemporalBench (MBA-short QA)	TVBench Acc	TOMATO Acc	MVBench Acc
现成图像编码器									
***DINOv2 ViT-g*$_{518}$**	1.1B/7B	45.7	67.1	22.4	62.3	26.8	47.6	32.0	61.8
***SigLIP2 ViT-g*$_{384}$**	1.1B/7B	48.1	**72.4**	26.2	66.8	25.7	48.7	33.2	64.0
***PE ViT-G/14*$_{448}$**	1.9B/7B	49.1	72.3	26.7	67.0	27.5	51.6	34.0	64.7
***V-JEPA 2 ViT-g*$_{512}$**	1B/7B	**52.3**	72.0	**31.1**	**69.2**	**33.3**	**55.9**	**37.0**	**67.7**

表 7 视觉编码器规模与分辨率的扩展。我们将视觉编码器从 3 亿参数扩展到 10 亿参数，并将输入分辨率从 256 像素提升至 512 像素。所有实验均使用相同的 LLM 主干（Qwen2-7B-Instruct）、数据和端到端训练（视觉编码器不冻结）设置。PerceptionTest 准确率在 SFT 后的验证集上报告。增大 V-JEPA 2 编码器规模和分辨率可提升 VidQA 任务的平均性能。

方法	参数量 编码器 / LLM	Avg.	PerceptionTest SFT / Acc	MVP Paired-Acc	TempCompass multi-choice	TemporalBench (MBA-short QA)	TVBench Acc	TOMATO Acc	MVBench Acc
端到端评估									
***V-JEPA 2 ViT-L*$_{256}$**	300M/7B	51.7	74.6	32.3	70.1	30.2	50.9	36.5	67.1
***V-JEPA 2 ViT-H*$_{256}$**	600M/7B	52.0	74.7	30.6	70.9	29.8	54.6	35.1	68.0
***V-JEPA 2 ViT-g*$_{256}$**	1B/7B	52.3	75.5	31.9	70.7	28.3	54.2	37.3	68.3
***V-JEPA 2 ViT-g*$_{384}$**	1B/7B	54.0	76.5	33.0	**71.7**	**33.1**	56.5	**39.0**	68.5
***V-JEPA 2 ViT-g*$_{512}$**	1B/7B	**54.4**	**77.7**	**33.7**	71.6	32.3	**57.5**	38.5	**69.5**

相同的 LLM 主干和训练设置。在此受控设置中，我们使用 Qwen2-7B-Instruct（Yang 等，2024a）并冻结视觉编码器。我们使用 1800 万个图像和视频-文本对齐样本。我们首先将 V-JEPA 2（以分辨率 **512×512** 预训练）与 DINOv2（Oquab 等，2023）、SigLIP-2（Tschannen 等，2025）和 Perception Encoder（Bolya 等，2025）进行比较。

我们观察到，V-JEPA 2 在冻结设置下展现出具有竞争力的性能，在所有测试基准（表 6）中均优于 DINOv2、SigLIP 和 Perception Encoder（PE），但在 PerceptionTest 上 V-JEPA 2 略逊于 SigLIP 和 PE。这一提升在 MVP、TemporalBench 和 TVBench 上尤为明显——这些基准主要侧重于时序理解。此外，由于我们仅更换了视觉编码器，我们提供了证据表明，未经语言监督训练的视频编码器可以优于经语言监督训练的编码器，这与传统认知相反（Tong et al., 2024; Li et al., 2024b; Liu et al., 2024d; Yuan et al., 2025）。结果还表明，在 VidQA 中使用视频编码器而非图像编码器可以改善时空理解，凸显了开发更好的视频编码器的必要性。

7.3 缩放视觉编码器规模与输入分辨率

先前工作（Fan et al., 2025）表明，扩大视觉编码器和输入分辨率可显著提升自监督图像编码器的VQA性能。因此，我们将V-JEPA 2从300M参数扩展至1B参数，并将输入分辨率从256像素提升至512像素，结果如表7所示。当输入分辨率固定为256像素、视觉编码器容量从300M提升至1B参数时，我们观察到PerceptionTest提升0.9分、TVBench提升3.3分、MVBench提升1.2分。此外，将输入分辨率提升至512像素可在所有下游任务上带来进一步提升，例如PerceptionTest提升2.2分、TemporalBench提升4.0分、TVBench提升3.3分。这些结果表明，进一步扩展视觉编码器和输入分辨率是提升VidQA性能的一个有前景的

表 8 与最先进方法的比较。我们使用完整的 8850 万样本对齐数据集，并采用与 PLM 8B Cho et al. (2025) 相同的方法进行训练，使用 Llama 3.1 作为骨干网络。我们观察到下游评估有显著提升，在 8B 模型类别中取得了最先进的结果。PerceptionTest 准确率是在 V-JEPA 2 使用 SFT 的测试集上报告的；所有其他结果均为零样本。

方法	参数量 编码器 / LLM	Avg.	PerceptionTest Test Acc	MVP Paired-Acc	TempCompass multi-choice	TemporalBench (MBA-short QA)	TOMATO Acc	TVBench Acc	MVBench Acc
$\leq 8B$ 视频语言模型文献中报告的结果									
InternVL-2.5 (Chen 等，2024)	300M/7B	**52.1**	**68.9**	**39.9**	**68.3**	**24.3**	**29.4**	**61.6**	**72.6**
Qwen2VL (Wang 等，2024a)	675M/7B	**47.0**	**66.9**	**29.2**	**67.9**	**20.4**	**31.5**	**46.0**	**67.0**
Qwen2.5VL (Qwen 团队等，2025)	1B/7B	**49.7**	**70.5**	**36.7**	**71.7**	**24.5**	**24.6**	**50.5**	**69.6**
PLM 8B (Cho 等，2025)	1B/8B	**56.7**	**82.7**	**39.7**	**72.7**	**28.3**	**33.2**	**63.5**	**77.1**
V-JEPA 2 ViT-g_{384} Llama 3.1 8B	1B/8B	**59.5**	**84.0**	**44.5**	**76.9**	**36.7**	**40.3**	**60.6**	**73.5**

改进VidQA性能的方向。

7.4 通过扩展数据提升最先进水平

在更好地理解了 V-JEPA 2 在受控设置下训练 MLLM 的能力之后，我们研究了增加对齐数据集规模以提升 VidQA 最先进水平的效果。正如 Cho 等人（2025）所观察到的，下游任务性能的阶跃式提升通常通过增加训练数据的规模来实现。为此，我们将 MLLM 训练数据的规模从 1800 万增加到完整的 8850 万（4.7×）。虽然提高模型分辨率有助于下游性能，但随之而来的挑战是在 LLM 输入中容纳大量视觉 token。因此，我们选择 V-JEPA 2 ViT-g_{384}，每帧产生 288 个视觉 token。我们遵循 Cho 等人（2025）的相同方案，使用 Llama 3.1 作为骨干来训练 V-JEPA 2 ViT-g_{384}。为简化训练过程，我们使用不带池化的 MLP 投影器。有关扩展训练设置的详细信息在附录 E 中描述。

均匀扩展数据能够提升下游基准性能，从而在多个基准上取得最先进的结果（表8）——PerceptionTest、MVP、TempCompass、TemporalBench 和 TOMATO。与当前最先进的 PerceptionLM 8B（Cho 等，2025）相比，我们观察到 PerceptionTest 测试集准确率提升 1.3 分，MVP 配对准确率提升 4.8 分，TempCompass 准确率提升 4.2 分，TemporalBench 短问答片段多二分类准确率提升 8.4 分，TOMATO 准确率提升 7.1 分。V-JEPA 2 在 TVBench 和 MVBench 上未能超越 PerceptionLM，但仍显著优于其他相关基线（InternVL 2.5、Qwen2VL 和 Qwen2.5VL）。这些结果凸显了扩展训练数据以实现视觉-语言对齐的必要性，并提供了证据表明，像 V-JEPA 2 这样在没有语言监督下预训练的编码器，在足够规模下能够取得最先进的结果。

8 相关工作

世界模型与规划。早在 Sutton 和 Barto（1981）以及 Chatila 和 Laumond（1985）的工作中，AI 研究者就试图构建使用世界内部模型的智能体——既对世界的动态进行建模，也对静态环境进行映射——以实现高效的规划与控制。先前的工作在模拟任务中研究了世界模型（Fragkiadaki 等，2015；Ha 和 Schmidhuber，2018；Hafner 等，2019b,a；Hansen 等，2022, 2023；Hafner 等，2023；Schrittwieser 等，2020；Samsami 等，2024），也在真实世界的运动与操作任务中进行了研究（Lee 等，2020；Nagabandi 等，2020；Finn 等，2016；Ebert 等，2017, 2018；Yen-Chen 等，2020）。世界模型方法要么直接在像素空间中学习预测模型（Finn 等，2016；Ebert 等，2017, 2018；Yen-Chen 等，2020），要么在学习到的表示空间中学习（Watter 等，2015；Agrawal 等，2016；Ha 和 Schmidhuber，2018；Hafner 等，2019b；Nair 等，2022；Wu 等，2023b；Tomar 等，2024；Hu 等，2024；Lancaster 等，2024），或者利用更具结构化的表示空间，例如关键点表示（Manuelli 等，2020；Das

等，2020）。先前在机器人任务上展示了真实世界性能的方法训练的是任务特定的世界模型，并且依赖于机器人所部署环境中的交互数据。评估的重点是展示世界建模方法在所探索任务空间内的性能，而非对新环境或未见物体的泛化能力。在本工作中，我们训练了一个任务无关的世界模型，并展示了其对新环境和物体的泛化能力。

近期一些工作利用互联网规模的视频和交互数据，面向自主机器人训练通用（任务无关的）动作条件视频生成模型（Bruce et al., 2024; Agarwal et al., 2025; Russell et al., 2025）。然而，迄今为止这些方法仅展示了在给定机器人动作的情况下生成视觉上合理的计划的能力，但尚未证明能够利用这些模型实际控制机器人。

其他工作探索了将生成建模集成到策略学习中（Du et al., 2024; Wu et al., 2023a; Zhao et al., 2025; Zhu et al., 2025; Du et al., 2023; Zheng et al., 2025; Rajasegaran et al., 2025）。与这一研究方向不同，我们的目标是通过模型预测控制而非策略学习来利用世界模型，以避免需要专家轨迹的模仿学习阶段。两种方法是正交的，未来可以结合。与我们的工作最接近的是，Zhou et al. (2024); Sobal et al. (2025) 表明可以分阶段或端到端地学习世界模型，并将其用于零样本求解规划任务。虽然这些先前的工作聚焦于小规模规划评估，但我们表明类似的原则可以扩展并用于求解真实世界的机器人任务。

用于机器人控制的视觉-语言-动作模型。近期在真实世界机器人控制中的模仿学习方法在策略学习方面取得了显著进展，展现出越来越好的泛化能力。这是通过利用在互联网规模视频和文本数据上预训练的视觉-语言模型实现的，这些模型随后通过使用专家演示的行为克隆进行微调（或适配）以预测动作（Driess et al., 2023; Brohan et al., 2023; Black et al., 2024; Kim et al., 2024; Bjorck et al., 2025; Black et al., 2025）。尽管这些方法展现出有前景的泛化结果，但尚不清楚它们是否能够学会预测训练数据中未曾演示过的行为，因为它们缺乏显式的世界预测模型，也未利用推理时的计算来进行规划。它们需要高质量的大规模遥操作数据，并且只能利用成功的轨迹。相比之下，我们专注于利用任何交互数据，无论其来自与环境的成功交互还是失败交互。

视觉基础模型。计算机视觉中的视频基础模型已经表明，由图像和/或视频构成的大规模观测数据集，可以被用来学习通用视觉编码器，这些编码器通过基于图像的自监督学习方法（Grill et al., 2020; Assran et al., 2023; Oquab et al., 2023; Fan et al., 2025）、基于视频的自监督学习方法（Bardes et al., 2024; Carreira et al., 2024; Wang et al., 2023; Rajasegaran et al., 2025）、带有弱语言监督的方法（Wang et al., 2024b; Bolya et al., 2025），或上述方法的组合（Tschannen et al., 2025; Fini et al., 2024），在广泛的下游任务上表现良好。然而，以往的工作往往侧重于使用基于探针的评估或在与大语言模型对齐后的视觉问答任务来进行理解评估。尽管这类任务推动了进展，但使智能体能够与物理世界交互仍然是视觉系统的一个重要目标（Gibson, 1979）。除了视觉理解任务上的结果之外，我们还研究了从视频中进行大规模自监督学习如何能够以零样本方式解决新环境中的规划任务。

9 结论

本研究展示了联合嵌入预测架构如何通过从网络规模数据和少量机器人交互数据中以自监督方式进行学习，产生一个能够在物理世界中理解、预测和规划的世界模型。V-JEPA 2 在需要运动理解的动作分类和人类动作预测任务上达到了最先进的性能。当与大语言模型对齐时，V-JEPA 2 在视频问答任务上也优于以往的视觉编码器。此外，利用 V-JEPA 2 的表征对动作条件世界模型 V-JEPA 2-AC 进行后训练，使真实世界机器人能够成功完成零样本抓取操作任务，例如拾取与放置。这些发现表明，V-JEPA 2 是朝着开发能够在环境中有效感知和行动的高级 AI 系统迈出的一步。

未来工作。未来有若干重要方向可以解决 V-JEPA 2 的局限性。首先，在本工作中，我们聚焦于需要预测未来大约 16 秒的任务。这使得能够从单张目标图像出发，为较简单的操作任务（如抓取和带物体伸取）进行规划。然而，要将其扩展到更长时域的任务（如拾取放置，甚至更复杂的任务），而不需要子目标，则需要在建模方面进一步的创新。开发能够跨多个空间和时间尺度、在不同抽象层次上进行预测的分层模型方法，是一个有前景的方向。

其次，如第 4 节所述，V-JEPA 2-AC 目前依赖于以图像目标指定的任务。尽管这对某些任务可能是自然的，但在其他情况下，基于语言的目标指定可能更为可取。扩展 V-JEPA 2-AC 以接受基于语言的目标——例如，通过让一个模型能够将基于语言的目标嵌入到 V-JEPA 2-AC 的表示空间中——是未来工作的另一个重要方向。第 7 节中描述的将 V-JEPA 2 与语言模型对齐的结果，可以作为起点。

最后，在这项工作中，我们将 V-JEPA 2 模型扩展到了适度的 10 亿参数规模。第 2 节的结果表明，在扩展至这一规模的过程中，性能持续提升。先前的工作已将视觉编码器扩展至高达 200 亿参数（Zhai 等，2022；Carreira 等，2024）。这一方向仍需开展更多工作，以开发出能够随规模持续带来性能提升的可扩展预训练方案。

致谢

我们感谢Rob Fergus、Joelle Pineau、Stephane Kasriel、Naila Murray、Mrinal Kalakrishnan、Jitendra Malik、Randall Balestriero、JulenUrain、Gabriel Synnaeve、MichelMeyer、Pascale Fung、Justine Kao、FlorianBordes、Aaron Foss、Nikhil Gupta、Cody Ohlsen、Kalyan Saladi、Ananya Saxena、Mack Ward、Parth Malani、Shubho Sengupta、Leo Huang、Kamila Benzina、Rachel Kim、Ana Paula Kirschner Mofarrej、Alyssa Newcomb、Nisha Deo、Yael Yungster、Kenny Lehmann、Karla Martucci，以及PerceptionLM团队（包括Christoph Feichtenhofer、Andrea Madotto、Tushar Nagarajan和Piotr Dollar）对本项目的反馈和支持。

十一、阅读笔记(zotero)

https://github.com/Nepenthe886/storage/tree/main/YRMHJJNC